

פרויקט גמר מדעי הנתונים

מגישים :

- נועם קדוש
- ניתאי בן אדמון
- עידן טגבה
- רוי בוקר

מרצה : ד"ר אביעד אלישר

הקדמה

פרויקט זה עוסק בניתוח הלך הרוח של משתמשים המשיכים לאוכלוסיית המטרה של אזרחי איראן ברשת החברתית X על בסיס תכנים טקסטואליים ונתוני פעילות של משתמשים פעילים בפלטפורמה. איראן מהווה מקרה בוחן ייחודי בשל המאפיינים החברתיים, הפוליטיים והתקשורתיים שלה, ובפרט לאור מגבלות חופש הביטוי במדיה המסורתית והשימוש הנרחב ברשתות חברתיות כמרחב חלופי לשיח ציבורי. במסגרת הפרויקט נאספו ונותחו נתונים בהיקף רחב, הכוללים ישויות מרכזיות (POIs), מאפייני משתמשים, קשרי עוקבים ותכני ציוצים לאורך תקופת זמן מוגדרת. התהליך משלב טכניקות מתקדמות מתחום מדעי הנתונים ולמידת מכונה, ובהן איסוף נתונים ממקורות חיצוניים Wikipedia ו-Wikidata, תיוג ידני מבוקר, אימון מסווגים בלמידה מונחית ולמידה אקטיבית, וכן ניתוח טקסטואלי מתקדם הכולל ניתוח סנטימנט, רגשות וזיהוי נושאים מרכזיים. מטרת הפרויקט היא לבנות תהליך שיטתי ומבוסס נתונים לזיהוי אוכלוסיית יעד רלוונטית, ולהפיק תובנות איכותיות על דפוסי השיח והלך הרוח של משתמשים איראנים ברשת החברתית.

מבוא ורקע

רשתות חברתיות מהוות כיום מקור מרכזי להבנת שיח ציבורי, עמדות ורגשות של קבוצות אוכלוסייה שונות. בעשורים האחרונים חלה עלייה משמעותית בשימוש בפלטפורמות דיגיטליות ככלי לביטוי אישי, פוליטי וחברתי, במיוחד במדינות שבהן קיימות מגבלות על חופש הביטוי במדיה המסורתית. במצבים אלו, הרשתות החברתיות משמשות מרחב חלופי לניהול דיון ציבורי, שיתוף חוויות והבעת עמדות שאינן זוכות לביטוי בערוצים רשמיים. איראן מהווה דוגמה בולטת לכך, שכן אזרחים רבים עושים שימוש נרחב ברשתות החברתיות לצורך ביטוי דעות והתמודדות עם סוגיות חברתיות ופוליטיות. פרויקט זה מתמקד בניתוח שיטתי של השיח הדיגיטלי של משתמשים איראנים, במטרה להבין את הלך הרוח העולה ממנו באמצעות כלים מתחום מדעי הנתונים.

מטרת הפרויקט

מטרת הפרויקט היא לזהות, לבנות ולנתח אוכלוסיית יעד של משתמשים איראנים ברשת חברתית מרכזית, ולהפיק תובנות על הלך הרוח שלהם על סמך תכנים טקסטואליים ונתוני פעילות. לשם כך,

הפרויקט מבוסס על תהליך רב שלבי הכולל איסוף נתונים ממקורות פתוחים, סינון משתמשים רלוונטיים, תיוג ידני מבוקר ואימון מודלים חישוביים ללמידה מונחית וללמידה אקטיבית. באמצעות שילוב שיטות אלו, נבנה תהליך אמין ומבוסס נתונים המאפשר ניתוח רגשות, סנטימנט ונושאים מרכזיים העולים מהשיח הציבורי לאורך זמן.

אוכלוסיית המטרה

אוכלוסיית המטרה בפרויקט זה כוללת משתמשים אנושיים המשויכים לאוכלוסייה האיראנית, הן תושבי איראן והן בני התפוצה האיראנית מחוץ למדינה. הדגש ניתן לזיהוי חשבונות פרטיים ולא חשבונות מוסדיים או ארגוניים, במטרה לנתח שיח אישי ואותנטי ככל האפשר. תהליך הזיהוי התבסס על שילוב של מוקדי משיכה מרכזיים, ניתוח קשרי עוקבים, איסוף מאפייני משתמשים ותיוג ידני מדויק. גישה זו נועדה להבטיח כי אוכלוסיית היעד שתנתח מייצגת משתמשים איראנים פעילים ורלוונטיים לשיח החברתי הנחקר.

למה הנושא מעניין וחשוב

הבנת הלך הרוח של האוכלוסייה האיראנית ברשתות חברתיות היא בעלת חשיבות מחקרית וחברתית רבה. השיח הדיגיטלי משקף לעיתים עמדות, רגשות ומתחים שאינם באים לידי ביטוי באמצעי תקשורת רשמיים, ובכך מאפשר הצצה "יחודית" למציאות החברתית והפוליטית במדינה. נוסף על כך, שימוש בכלים חישוביים לניתוח שיח מאפשר מעבר מהתרשמות איכותנית לניתוח כמותי ושיטתי, המבוסס על נתונים בהיקף רחב. הפרויקט מדגים כיצד ניתן לשלב מדעי נתונים ולמידת מכונה לצורך חקר תופעות חברתיות מורכבות, ומהווה בסיס להפקת תובנות ולהשוואות עתידיות בין תקופות זמן, נושאים וקבוצות אוכלוסייה שונות.

איסוף ישויות מוקדי משיכה מוויקיפדיה

בשלב זה בוצע איסוף שיטתי של ישויות מוקדי משיכה (POIs) הרלוונטיות לאוכלוסיית המטרה האיראנית, מתוך אנציקלופדיית ויקיפדיה. מטרת שלב זה הייתה לבנות רשימה רחבה, מגוונת ואמינה של אישים, ארגונים וגופים ציבוריים אשר מהווים מוקדי עניין מרכזיים עבור משתמשים איראנים ברשתות החברתיות, ובהסתברות גבוהה יש להם קהל עוקבים משמעותי מאוכלוסיית היעד. האיסוף התבסס על קטגוריות מוגדרות מראש בוויקיפדיה, הכוללות תחומים שונים כגון פוליטיקה, תקשורת, תרבות, ספורט, רפואה, אקדמיה ואקטיביזם חברתי, וזאת במטרה לייצר כיסוי רחב ככל האפשר של תחומי השיח המרכזיים בחברה האיראנית.

מבחינה טכנית, תהליך האיסוף בוצע באמצעות שימוש בממשק התכנות של ויקיפדיה, תוך סריקה רקורסיבית של קטגוריות ותתי קטגוריות. עבור כל קטגוריה בוצע מעבר רוחבי (סריקה ברוחב) אשר כלל שליפת דפי תוכן ממשיים וכן זיהוי תתי קטגוריות להמשך סריקה, עד למיצוי מלא של מבנה הקטגוריה. מכל דף שנאסף הופקו שם הישות וקישור ישיר לערך בוויקיפדיה, ונבנתה טבלת נתונים אחידה לכל קטגוריה. לצורך שמירה על סדר ועמידה בהנחיות הפרויקט, הנתונים נשמרו כקובצי טבלאות נפרדים, כאשר לכל קטגוריה נוצר קובץ ייעודי בתוך תיקיית מוקדי המשיכה, במבנה תיקיות אחיד וברור.

לשלב זה חשיבות מרכזית בהצלחת הפרויקט כולו, שכן איכות וכיסוי מוקדי המשיכה משפיעים באופן ישיר על איכות אוכלוסיית המועמדים שתיבנה בהמשך. מוקדי משיכה שאינם מייצגים נאמנה את החברה האיראנית או שאינם מגוונים דיים עלולים להוביל להטיה בשלב איסוף העוקבים ולפגוע באמינות הניתוחים המאוחרים יותר. באמצעות שימוש בוויקיפדיה כמקור נתונים אמין, מובנה וניטרלי

יחסית, ובאמצעות הרחבה יזומה של תחומי הקטגוריות, הונחה תשתית נתונים רחבה ואיכותית להמשך שלבי הפרויקט, ובפרט לשלבי איתור משתמשים, תיוג, אימון מסווגים וניתוח הלך הרוח.

	Name	Wikipedia_Link
> government_ministers_of_iran	Abdul Aziz Mala	https://en.wikipedia.org/w
> healthcare_in_iran	Ali Afshari	https://en.wikipedia.org/w
> hospitals_in_iran	Jamal al-Din al-A	https://en.wikipedia.org/w
> hospitals_of_iran_by_city	Naza Alakija	https://en.wikipedia.org/w
▼ iranians_activists	Mohammad-Rez	https://en.wikipedia.org/w
iranians_activists_wikipedia_with_wik	Mohsen Alijani-2	https://en.wikipedia.org/w
iranians_activists_wikipedia_with_wik	Alireza Shir Moh	https://en.wikipedia.org/w
iranians_activists_wikipedia_with_wik	Taqi Arani	https://en.wikipedia.org/w
iranians_activists_wikipedia.csv	Yasaman Aryani	https://en.wikipedia.org/w
> iranians_actors	Atefe Asadi	https://en.wikipedia.org/w
> iranians_athletes	Akbar Atri	https://en.wikipedia.org/w
> iranians_ayatollahs	Yousef Azizi (Bar	https://en.wikipedia.org/w
> iranians_bloggers	Reza Baluchi	https://en.wikipedia.org/w
> iranians_cardiologists		

שלב 3 - העשרת ישויות מוקדי המשיכה באמצעות נתונים מובנים מויקיידאטה

בשלב זה בוצעה העשרה שיטתית של ישויות מוקדי המשיכה שנאספו בשלב הקודם, באמצעות שילוב נתונים מובנים ממאגר ויקיידאטה. בעוד שויקיפדיה מספקת רשימות ישויות וקישורים לערכים טקסטואליים, ויקיידאטה מאפשרת גישה למידע מתווג, אחד ומבוסס סכמה, אשר חיוני לצורך ניתוח חישובי מתקדם בשלבים המאוחרים של הפרויקט. מטרת שלב זה הייתה להרחיב את בסיס הנתונים הקיים ולהפוך אותו למאגר עשיר בתכונות כמותיות וקטגוריות, המאפשרות סיווג, השוואה וניתוח שיטתי של הישויות.

העיבוד בוצע באופן אוטומטי עבור כלל תיקיות מוקדי המשיכה שנוצרו בשלב הקודם. עבור כל קובץ נתונים הותאם מזהה ייחודי במאגר ויקיידאטה לכל ישות, באמצעות קישור לערך המקביל בוויקיפדיה. לאחר שלב ההתאמה, נשלפו מאפיינים מובנים באמצעות שאלות נתונים ייעודיות, ובהם מגדר, עיסוק, אזרחות, מקום לידה ותאריך לידה. הנתונים נשלפו בקבוצות על מנת לשפר יעילות ולצמצם עומסים, ונשמרו בקובצי נתונים ייעודיים המרחיבים את הקבצים המקוריים. תהליך זה כלל גם מנגנוני בקרה, טיפול בשגיאות ושמירה על עקביות מבנית בין כלל הקבצים.

לשלב זה חשיבות מהותית בהנחת התשתית האנליטית של הפרויקט. מאפיינים מובנים מויקיידאטה מאפשרים מעבר מניתוח טקסטואלי חופשי בלבד לניתוח מבוסס תכונות, המאפשר אימון מסווגים, פילוח אוכלוסיות וביצוע בדיקות סטטיסטיות מהימנות. בנוסף, העשרת הנתונים מאפשרת בהמשך לזהות דפוסים בין סוגי ישויות שונים, לבחון הבדלים בין תחומי עיסוק, ולשפר את איכות תהליכי הסינון והתיוג של משתמשים ברשת החברתית. לפיכך, שלב זה מהווה נדבך מרכזי בקישור שבין שלב איסוף הנתונים הראשוני לבין שלבי הלמידה החשובית וניתוח הלך הרוח שבאים לאחריו.

iranian_rappers		Name	Wikipedia_Link	Wikidata_qid	Wikidata_url	Wikidata_gender	Wikidata_occupation	Wikidata_country	Wikidata_place
		Bahar Dehkordi	https://en.wikipedia.org/wiki/Bahar_Dehekordi	Q125429300	https://www.wikidata.org/wiki/Q125429300	female	actor; singer	Iran	Iran
		Erfan (rapper)	https://en.wikipedia.org/wiki/Erfan_(rapper)						
		Fadaei	https://en.wikipedia.org/wiki/Fadaei	Q114949969	https://www.wikidata.org/wiki/Q114949969	male	rapper; singer		Tehran
		Moltafet	https://en.wikipedia.org/wiki/Moltafet	Q124079907	https://www.wikidata.org/wiki/Q124079907	male			
		Shahin Najafi	https://en.wikipedia.org/wiki/Shahin_Najafi	Q983297	https://www.wikidata.org/wiki/Q983297	male	guitarist; singer	Iran	Bandar-e Anzali
		Nazar (rapper)	https://en.wikipedia.org/wiki/Nazar_(rapper)						
		Bahram Nouraei	https://en.wikipedia.org/wiki/Bahram_Nouraei	Q4842856	https://www.wikidata.org/wiki/Q4842856	male	singer; songwriter	Iran	Tehran
		Reveal (rapper)	https://en.wikipedia.org/wiki/Reveal_(rapper)						
		Toomaj Salehi	https://en.wikipedia.org/wiki/Toomaj_Salehi	Q108611372	https://www.wikidata.org/wiki/Q108611372	male	activist; rapper; singer	Iran	Gerd Bisheh, Chaharmahal and Bakhtiari Province
		Sasy	https://en.wikipedia.org/wiki/Sasy	Q4682251	https://www.wikidata.org/wiki/Q4682251	male	composer; rapper	Iran	Ahvaz
		Ali Sorena	https://en.wikipedia.org/wiki/Ali_Sorena	Q47540436	https://www.wikidata.org/wiki/Q47540436	male	lyricist; rapper; singer	Iran	
		Amir Tataloo	https://en.wikipedia.org/wiki/Amir_Tataloo	Q6417825	https://www.wikidata.org/wiki/Q6417825	male	composer; rapper	Iran	Tehran
		Yas (rapper)	https://en.wikipedia.org/wiki/Yas_(rapper)						
		Zedbazi	https://en.wikipedia.org/wiki/Zedbazi	Q5949579	https://www.wikidata.org/wiki/Q5949579				
		Ghogha (rapper)	https://en.wikipedia.org/wiki/Ghogha_(rapper)						
		Salome MC	https://en.wikipedia.org/wiki/Salome_MC	Q7405619	https://www.wikidata.org/wiki/Q7405619	female	graffiti artist; rapper	Iran	

שלב 4 – איתור שמות משתמש ברשת החברתית עבור מוקדי המשיכה

בשלב זה בוצע תהליך אוטומטי לאיתור שמות המשתמש של מוקדי המשיכה ברשת החברתית, במטרה לקשר בין הישויות שנאספו מויקיפדיה והועשרו באמצעות ויקידאטה לבין חשבונות פעילים בפועל.
שלב זה מהווה חוליית מעבר קריטית בין איסוף ישויות "תיאורטיות" (אישים וארגונים כפי שהם מופיעים במקורות ידע פתוחים) לבין יצירת בסיס נתונים המבוסס על פעילות אמיתית ברשת חברתית, אשר מאפשר בהמשך לאסוף נתוני מטא־דאטה, עוקבים ותכנים לצורך ניתוח הלך הרוח. התהליך יושם על כל תיקיות מוקדי המשיכה שנוצרו בשלבים הקודמים, כך שלכל קטגוריה נבנתה טבלה מעודכנת הכוללת את פרטי הישות יחד עם שם המשתמש והקישור הישיר לחשבון.

מבחינה טכנית, זיהוי החשבונות בוצע בגישה דו־שלבית על מנת לשפר את שיעור ההצלחה ולצמצם טעויות. בשלב הראשון נשלפה עבור כל ישות ידית המשתמש הרשמית כפי שהיא מופיעה בויקי־דאטה (שדה ייעודי לקישור לרשת החברתית), באמצעות שאילתות נתונים מרוכזות. לשם יעילות וביצועים, השאילתות הורצו בקבוצות, וכל התוצאות נשמרו במנגנון זיכרון מקומי לצורך שימוש חוזר והפחתת קריאות חוזרות למקורות החיצוניים. בשלב השני, עבור ישויות שבהן לא נמצא שם משתמש באמצעות ויקידאטה, הופעלה שיטת גיבוי המבוססת על ניתוח דף הויקיפדיה עצמו: נשלפו קישורים חיצוניים וטקסט מקור של הערך, והופעלו כללים לזיהוי כתובות של חשבונות ברשת החברתית ולהפקת שם המשתמש מתוכן. לאחר מכן בוצע ניקוי תקני של שמות המשתמש כדי להבטיח התאמה לכללי המבנה (למשל אורך חוקי ותווים מותרים), ונוצר לכל שם משתמש קישור ישיר לחשבון.

התוצר של שלב זה הוא קובץ נתונים מעודכן לכל תיקיית מוקדי משיכה, הכולל עמודה ייעודית לשם המשתמש ועמודה לקישור לחשבון. שלב זה חשוב במיוחד מאחר שהוא משפיע ישירות על היכולת להמשיך לשלבי איסוף נתונים מהרשת החברתית: ללא התאמה איכותית בין ישויות לחשבונות, לא ניתן לאסוף מטא־דאטה, עוקבים ותכנים בצורה אמינה. בנוסף, שילוב שתי שיטות איתור והפעלת מנגנוני בקרה ושמירה על תוצאות ביניים מאפשרים לשפר את הכיסוי ולהקטין את מספר הישויות שאינן ניתנות למיפוי, ובכך להגדיל את איכות המאגר שעל בסיסו תיבנה אוכלוסיית המועמדים בהמשך הפרויקט.

שלב 5 – איחוד והרחבת מאגר מוקדי המשיכה באמצעות קובץ חיפוש ידני מרכזי

בשלב זה בוצעה בנייה ואיחוד של קובץ מרכזי עבור מוקדי המשיכה, במבנה התואם להנחיות הקורס לקובץ "חיפוש ידני". מטרת השלב היא לרכז במקום אחד את כלל הישויות שאותרו להן ידיות משתמש ברשת החברתית, יחד עם מילת החיפוש ששימשה לאיתורן, ובכך לאפשר ניהול עקבי של

תהליך הרחבת מוקדי המשיכה והכנה לשלב איסוף הנתונים מהרשת החברתית. מבחינה תפעולית, במקום ליצור את הקובץ ידנית, הופעל תהליך אוטומטי שסורק את כל תיקיות מוקדי המשיכה שנוצרו בשלבים הקודמים, מאתר בכל תיקייה את קבצי הפלט שבהם כבר קיימת עמודת שם משתמש (קבצי "עם טוויטר"), ומחלץ מהם את שם הישות ושם המשתמש. בנוסף, הוגדר מנגנון למיפוי "מילת חיפוש" לכל תיקייה, כך שכל רשומה מקבלת תיוג עקבי של ההקשר שבו אותה (למשל סוג הישות והקישור לאיראן), ובמקרים שבהם אין מיפוי מפורש — מתבצעת הסקה אוטומטית של מילת חיפוש סבירה מתוך שם התיקייה. לאחר איחוד הנתונים מכל התיקיות, בוצע ניקוי של שמות המשתמש, יצירת קישור ישיר לחשבון, וסינון כפילויות כדי להבטיח שמאגר היעד אינו סופר את אותו משתמש מספר פעמים. התוצר הסופי הוא קובץ מרכזי בשם Manual_Search_POIs.csv הנשמר תחת תיקיית מוקדי המשיכה, הכולל לכל רשומה מילת חיפוש, שם ישות, שם משתמש וקישור לחשבון, ומהווה שכבת תיעוד חשובה המאפשרת מעקב אחר איכות הכיסוי והרחבתו לפני המעבר לשלבים הבאים של איסוף מטא-דאטה וקשרי עוקבים.

	keyword	poi_name	twitter_username	twitter_url	source_folder
0	Iran activist	Execution of Majid Kazemi	1500tasvir	https://x.com/1500tasvir	iranian_activists
1	Iran candidate	まゆみん	2011	https://x.com/2011	Candidates
2	Iran writer	Mehrdad Afsari	2011	https://x.com/2011	iranian_writers
3	Iran candidate	2012 ABC	2012	https://x.com/2012	Candidates
4	Iran writer	Behdad Sami	2012	https://x.com/2012	iranian_writers
5	Iran actor	Michael Shahrestani	2015	https://x.com/2015	iranian_actors
6	Iran candidate	NaN	2015	https://x.com/2015	Candidates
7	Iran film actor	Michael Shahrestani	2015	https://x.com/2015	iranian_film_actors
8	Iran president	Joint Comprehensive Plan of Action	2015	https://x.com/2015	presidents_of_iran
9	Iran president	Reactions to the Joint Comprehensive Plan of A...	2015	https://x.com/2015	presidents_of_iran

השלמת שלב איסוף מוקדי המשיכה – התמודדות עם חוסרים וקישורים חלקיים

במהלך תהליך איסוף מוקדי המשיכה התברר כי חלק מהישויות שאותו כפעילות ברשת החברתית אינן כוללות קישור ישיר לערך ויקיפדיה במסגרת האיסוף הראשוני. מצב זה נבע ממספר גורמים, ובהם הבדלים בין מבנה קטגוריות בוויקיפדיה, אי אחידות בכתיבת שמות ישויות, או חוסר קישור מפורש בין שם הישות לערך אנציקלופדי קיים. חוסרים מסוג זה עלולים לפגוע בהמשכיות הצנרת המחקרית, שכן קישור לוויקיפדיה משמש נקודת מוצא מרכזית להשלמת נתונים ממקורות נוספים ולשמירה על עקביות בין שלבי הפרויקט.

כדי להתמודד עם קושי זה, יושם תהליך משלים שמטרתו לצמצם אובדן נתונים ולשפר את שלמות המאגר. עבור ישויות שלהן נמצא חשבון פעיל ברשת החברתית אך לא נמצא להן קישור ויקיפדיה בשלב הראשוני, בוצע חיפוש יזום ומבוקר של ערכים רלוונטיים על בסיס שם הישות. תהליך זה התבסס על התאמה הסתברותית לשם הערך הקרוב ביותר והעדפת תוצאות חד משמעיות בלבד, במטרה למנוע שיוך שגוי. ישויות שנמצאה להן התאמה אמינה שולבו מחדש במאגר, בעוד שישויות שלא נמצא להן ערך מתאים נשמרו בנפרד ולא נכללו בשלבים הבאים.

התמודדות זו אפשרה לשפר את כיסוי מוקדי המשיכה ולהפוך את מאגר הנתונים לעקבי ואחיד יותר, תוך שמירה על עקרון הזהירות המחקרית. בכך הוגדל מספר הישויות שניתן להעשיר במידע מובנה ולהמשיך עבורן לשלבי סינון, תיוג ואימון מודלים, ללא הכנסת הטיית או שגיאות שיוך. שלב זה מדגים את החשיבות של בקרה ואימות גם בתהליכי איסוף אוטומטיים, ואת הצורך בהתערבות מתודולוגית כאשר נתוני המקור אינם שלמים.


שלב 6 – סטטיסטיקות ביניים להערכת איכות ושלמות

נתוני מוקדי המשיכה


בשלב זה בוצעה הערכת איכות ושלמות של מאגר מוקדי המשיכה שנאסף עד כה, במטרה למדוד באופן כמותי את הצלחת תהליך האיסוף ולזהות קטגוריות חזקות לעומת קטגוריות חלשות מבחינת כיסוי הנתונים. בשלב זה נדרשנו לבדוק את "שרשרת האיסוף" לכל קטגוריה: כמה ישויות נאספו מויקיפדיה, לכמה מהן הצלחנו להתאים מזהה במאגר ויקידאטה, ולכמה מהן נמצא בפועל חשבון ברשת החברתית. לשם כך הופעל תהליך עיבוד רוחבי על כלל תיקיות מוקדי המשיכה, כאשר עבור כל קטגוריה נספרו ערכים ייחודיים בלבד (ללא כפילויות) בכל מקור מידע, כדי למנוע ניפוח מלאכותי של התוצאות ולהפיק מדד אמין לייצוג בפועל. ספירת ויקיפדיה התבססה על שמות ישויות ייחודיים, ספירת ויקידאטה התבססה על מזהים ייחודיים כאשר היו זמינים, וספירת הרשת החברתית התבססה על שמות משתמש ייחודיים לאחר ניקוי ערכים ריקים ולא תקינים. התוצאות רוכזו לקובץ מסכם אחד הכולל לכל קטגוריה את שלושת המדדים, וכן חושב מדד נוסף של שיעור הצלחה, המייצג את אחוז הישויות שנמצאו להן חשבונות ברשת החברתית מתוך כלל הישויות שנאספו מויקיפדיה.

לצד הטבלה המסכמת, הופקו גם הדמיות שמטרתן לאפשר זיהוי מהיר של דפוסי הצלחה: תרשים עמודות המציג את שיעור ההצלחה לפי קטגוריה, וכך מאפשר להשוות בין תחומי תוכן שונים (למשל פוליטיקה, רפואה, תקשורת ותרבות) ולהבין היכן איתור חשבונות היה יעיל יותר. בנוסף, הופקה דיאגרמת ון המציגה חפיפה בין מקורות המידע, שמטרתה להמחיש את הפערים בין "ישויות שנמצאות ברמת ידע אנציקלופדי" לבין "ישויות שניתנות למיפוי לחשבונות פעילים". מבחינה מחקרית, שלב זה חיוני משום שהוא מהווה נקודת בקרה לפני המעבר לשלבים עתירי משאבים כמו איסוף עוקבים, תיוג ידני ואימון מודלים: באמצעות הסטטיסטיקות ניתן להחליט אילו קטגוריות שווה להרחיב או לשפר, אילו קטגוריות עלולות ליצור הטיה עקב ייצוג חסר, והיכן נדרש חיזוק של תהליך המיפוי לחשבונות. בכך שלב 6 משמש מנגנון איכות המפחית סיכון לשגיאות בשלבים המאוחרים ומבסס תשתית אמינה להמשך בניית אוכלוסיית המועמדים וניתוח הלך הרוח.

Overlap Between Wikipedia, Wikidata, and Twitter Coverage
(Total POI Entities)



Folder	Category_name	Wikipedia_count	Wikidata_count	Twitter_count	Success_rate
19th-century_ira	19Th-Century Ira	11	9	0	0
21st-century_ira	21St-Century Ira	26	26	5	19.2
government_mir	Government Mir	462	444	18	3.9
healthcare_in_ira	Healthcare In Ira	427	394	15	3.5
hospitals_in_iran	Hospitals In Iran	26	24	0	0
hospitals_of_iran	Hospitals Of Iran	0	0	0	0
iranian_activists	Iranian Activists	1010	904	107	10.6
iranian_actors	Iranian Actors	637	611	61	9.6
iranian_athletes	Iranian Athletes	115	112	0	0
iranian_ayatollah	Iranian Ayatollah	215	205	6	2.8
iranian_bloggers	Iranian Bloggers	35	33	6	17.1
iranian_cardiolog	Iranian Cardiology	5	5	0	0
iranian_comedia	Iranian Comedia	40	39	7	17.5
iranian_correspo	Iranian Correspo	0	0	0	0
iranian_dissident	Iranian Dissident	110	104	14	12.7
iranian_economi	Iranian Economic	67	67	5	7.5
iranian_editors	Iranian Editors	38	37	2	5.3
iranian_feminists	Iranian Feminists	113	111	13	11.5
iranian_film_acto	Iranian Film Acto	467	449	35	7.5
iranian_football_	Iranian Football	205	200	5	2.4
iranian_footballe	Iranian Footballer	1629	1555	31	1.9
iranian_human_r	Iranian Human R	207	205	22	10.6



שלב 7 – איסוף מטא-דאטה על חשבונות מוקדי המשיכה ברשת החברתית

בשלב זה נאסף מידע תיאורי ומבני על חשבונות מוקדי המשיכה שאותרו בשלבים הקודמים, במטרה לאפיין את פרופיל החשבונות ולבסס מאגר נתונים איכותי להמשך בניית אוכלוסיית המועמדים. לאחר שבשלב הקודם בוצעה התאמה בין ישויות לבין שמות משתמש, שלב זה מתמקד בהשלמת מאפייני חשבון בסיסיים, כגון שם תצוגה, תיאור פרופיל, מספר עוקבים, מספר נעקבים, היקף פעילות, מיקום, מאפייני אימות וסטטוס חשבון. מאפיינים אלה משמשים בהמשך הן לניתוח תיאורי של מוקדי המשיכה עצמם והן כתשתית לשלבי איסוף רשימות עוקבים ונעקבים, ולכן שלמותם ודיוקם משפיעים ישירות על איכות הצנרת המחקרית כולה.

האתגר המרכזי בשלב זה הוא איסוף מידע ללא שימוש בממשק רשמי המחייב הרשאות, ולכן הוטמעה גישה מבוססת גלישה אוטומטית המדמה שימוש אנושי בדפי פרופיל. השיטה מבצעת טעינה מבוקרת של עמודי המשתמשים, איתור רכיבי מידע מרכזיים בתוך העמוד, וחילוץ הערכים הרלוונטיים תוך התמודדות עם שונות במבנה התצוגה ועם מקרים שבהם מידע חסר או בלתי נגיש. כדי להפחית חסימות ושגיאות, הוגדרו מנגנוני האטה אקראיים בין בקשות, ניסיונות חוזרים במקרה של כשל זמני, ושמירה תקופתית של נתוני ביניים כדי לא לאבד תוצאות במקרה של עצירה או תקלה. בנוסף, הושם דגש על סיווג סטטוס החשבון, כולל הבחנה בין חשבון פעיל לחשבון מוגן, מושעה, לא נמצא או מושבת, שכן סטטוסים אלה משפיעים על היכולת להמשיך ולאסוף בהמשך נתונים נוספים כגון רשימות עוקבים ותכנים. בסיום השלב נשמר קובץ נתונים מרכזי המאחד את פרטי המטא-דאטה של כלל חשבונות מוקדי המשיכה, וכן נשמר רישום נפרד של חשבונות שבהם האיסוף נכשל לצורך בדיקה חוזרת או סינון. שלב זה מהווה נקודת מעבר חיונית מאיתור שמות משתמש לאפיון מלא של חשבונות, ומספק בסיס איכותי להמשך ניתוח סטטיסטי של מוקדי המשיכה ולשלבי בניית רשת העוקבים של אוכלוסיית היעד.

Username	Display_name	Description	Followers_count	Following_count	Statuses_count	Location	Profile_image
music	Music		9400000	117	21500		https://pbs.tv
statedept	Department of S	Leading U.S. fore For all Departme state.gov/social	6500000	445	85400	Washington, DC	https://pbs.tv
tcsavunma	T.C. Milli Savun	T.C. Milli Savunm	3600000	34	25400	Bakanlıklar/ANK	https://pbs.tv
refugees	UNHCR, the UN	We protect the r We hide or dele	2700000	2466	102000	120 countries	https://pbs.tv
alikarimi_ak8	ali karimi		2100000	30	631	تهران, ایران	https://pbs.tv
IranIntl	ایران اینترנشنال	یوشش می دهد 0044783000700 telegram.me/iran	2100000	61	326400	London, UK	https://pbs.tv
khamenei_ir	Khamenei.ir	News, messages @KhameneiBanc I AZ: @az_Khamenei I FA: @Khamenei_fa I AR: @ar_Khamenei	2000000	26	13200	Islamic Republic	https://pbs.tv
amnesty	Amnesty Interna	We defend hum For media enqui @amnestypress at press@amne	2000000	3550	28300	Global	https://pbs.tv
iranintlbrk	تشنال - خبر فوری	#ایران اینترنشنال ای ایران اینترنشنال @IranIntl	1700000	9	295700	London, UK	https://pbs.tv
JZarif	Javad Zarif	Husband, father, Founder/Preside PAIAB.org) Professor; former diplomat	1600000	10	1478		https://pbs.tv

אתגר באיסוף מספר הפרסומים – פתרון באמצעות אימות משתמש ומנגנוני התאוששות

במהלך איסוף המטא־דאטה על חשבונות מוקדי המשיכה התברר כי שדה היקף הפעילות של החשבון, המתבטא במספר הפרסומים הכולל, אינו נאסף באופן עקבי עבור חלק משמעותי מהחשבונות. בחלק מהמקרים הערך התקבל כחסר או כ־אפס, למרות שהחשבונות פעילים, וזאת בשל מגבלות גישה לתצוגה מלאה ללא אימות, שונות במבנה דפי הפרופיל, טעינה חלקית של רכיבי העמוד, וכן מנגנוני הגנה של הפלטפורמה המגבילים איסוף אוטומטי בקצב גבוה. חוסר עקביות בשדה זה פוגע ביכולת לבצע בהמשך ניתוחים כמותיים על רמת פעילות, לסנן חשבונות חשודים או לא פעילים, ולהשתמש בתכונה זו כחלק ממערך התכונות בשלבי סיווג.

כדי להתמודד עם הקושי, בוצע תהליך השלמה ייעודי המבוסס על גישה מאומתת לחשבונות, תוך שימוש בסשן התחברות קיים על בסיס עוגיות, במטרה להגדיל את שיעור ההצלחה בקבלת תצוגה מלאה של נתוני הפרופיל. בנוסף, הוטמעו מנגנוני התמודדות עם חסימות ושינויי תצוגה: הוגדרו זמני המתנה ארוכים ואקראיים בין פניות כדי להפחית זיהוי אוטומטי, בוצעו רענונים תקופתיים של הסשן כדי לשמור על הרשאות פעילות, ובוצעו אתחולים יזומים של סביבת הגלישה כדי לצמצם הצטברות חסימות במהלך ריצה ארוכה. במקביל, הוגדר מנגנון לזיהוי מצב שבו מתקבלת תצוגת התחברות במקום דף פרופיל תקין, ובמקרים אלו בוצעה התאוששות הכוללת חידוש סשן והמשך עיבוד. בסיום התהליך עודכן מאגר המטא־דאטה כך ששדה מספר הפרסומים הושלם עבור חלק גדול מהחשבונות, ובכך שופרה שלמות הנתונים ואפשרנו שימוש עקבי בתכונה זו בשלבי הניתוח והסינון המאוחרים.

	username	display_name	followers_count	statuses_count
0	music	Music	9400000	21500
1	statedept	Department of State	6500000	85400
2	tcsavunma	T.C. Milli Savunma Bakanlığı	3600000	25400
3	refugees	UNHCR, the UN Refugee Agency	2700000	102000
4	alikarimi_ak8	ali karimi	2100000	631
5	IranIntl	ایران اینترنشنال	2100000	326400
6	khamenei_ir	Khamenei.ir	2000000	13200
7	amnesty	Amnesty International	2000000	28300
8	iranintlbrk	ایران اینترنشنال - خبر فوری	1700000	295700
9	JZarif	Javad Zarif	1600000	1478

סינון חשבונות לא פעילים – בקרת איכות על מאגר המטא־דאטה

לאחר השלמת איסוף המטא־דאטה על חשבונות מוקדי המשיכה, התברר כי חלק מהחשבונות במאגר אינם מייצגים חשבונות פעילים בפועל. חשבונות אלו כללו ערכים אפסיים בכל מדדי הפעילות המרכזיים: מספר עוקבים, מספר נעקבים ומספר פרסומים. תבנית זו מצביעה בדרך כלל על חשבונות שנחקו, הושעו, או שאינם נגישים עוד לצפייה ציבורית, ולעיתים אף על חשבונות שמעולם לא היו

פעילים. הכללת חשבונות מסוג זה עלולה לפגוע באיכות הניתוחים המאוחרים, להטות סטטיסטיקות בסיסיות, ולהכניס רעש מיותר לשלבים של בניית רשת עוקבים וניתוח הלך הרוח.

כדי להתמודד עם קושי זה, בוצע שלב סינון ייעודי שמטרתו לנקות את המאגר מחשבונות שאינם תורמים מידע שימושי למחקר. חשבונות זוהו כלא פעילים רק כאשר שלושת מדדי הפעילות המרכזיים היו אפסיים בו זמנית, על מנת להימנע מהסרה שגויה של חשבונות חדשים או חשבונות בעלי פעילות נמוכה אך לגיטימית. חשבונות שעמדו בקריטריון זה הוסרו מהמאגר, והנתונים עודכנו כך שהמאגר הסופי יכלול רק חשבונות פעילים או כאלה שניתן לאפיין את פעילותם באופן אמין. שלב ניקוי זה תרם לשיפור מהותי באיכות הנתונים, הפחית הטיות הנובעות מחשבונות "מתים", והבטיח כי השלבים הבאים בפרויקט יתבססו על אוכלוסיית משתמשים רלוונטית, פעילה ובעלת משמעות אנליטית.

תיקון נתונים חלקיים בפרופילים – השלמת עוקבים ונעקבים עבור חשבונות עם חוסר עקביות

במהלך בקרת האיכות על מאגר המטא-דאטה של מוקדי המשיכה זוהתה בעיה מהותית של חוסר עקביות: עבור חלק מהחשבונות הופיע מספר פרסומים חיובי (כלומר החשבון פעיל ומייצר תוכן), אך במקביל מספר העוקבים ומספר הנעקבים נשמרו כ-אפס. תבנית זו אינה סבירה מבחינה התנהגותית ומעידה ברוב המקרים על כשל איסוף נקודתי, כגון טעינה חלקית של רכיבי דף הפרופיל, שינוי זמני במבנה התצוגה, או מגבלות גישה שהובילו לכך שחלק מהשדות לא נשלפו בזמן הריצה הראשונית. השארת ערכים אלו כ-אפס עלולה לפגוע באופן משמעותי בשימוש בתכונות הללו בהמשך, למשל בעת סינון חשבונות, בניית רשת קשרים, או הפקת סטטיסטיקות תיאוריות אמינות.

כדי להתמודד עם הבעיה, בוצע תהליך תיקון ממוקד שהתמקד רק בקבוצת החשבונות הבעייתיים (חשבונות עם פרסומים חיוביים אך עוקבים ונעקבים אפסיים). עבור חשבונות אלו בוצעה גישה מחודשת לדפי הפרופיל תחת ששן מאומת, במטרה לשפר את סיכויי הגישה לנתוני הפרופיל המלאים ולהפחית חסימות. החילוץ הוגבל באופן מכוון לשני שדות בלבד – עוקבים ונעקבים – כדי לצמצם עומס ולשפר יציבות, תוך שימוש במספר מנגנוני התאוששות כגון רענון תקופתי של ההרשאה, אתחול סביבת הגלישה בקצב קבוע, והשהיות אקראיות בין פניות כדי להפחית זיהוי אוטומטי. התוצאות שולבו חזרה במאגר המרכזי תוך עדכון שדות חסרים בלבד, ובכך נשמרו נתונים תקינים שכבר נאספו ולא בוצעה "דריסה" של ערכים קיימים.

תהליך תיקון זה שיפר את שלמות מאגר המטא-דאטה והקטין הטיות הנובעות מכשלים טכניים באיסוף. כתוצאה מכך, תכונות מרכזיות כגון מספר עוקבים ונעקבים הפכו לשימושיות באופן עקבי יותר, והמאגר הסופי הפך מתאים יותר לשלבים הבאים של הפרויקט שבהם נדרשת הסתמכות על מדדי פעילות וקישוריות לצורך סינון, יצירת אוכלוסיית מועמדים וניתוח השיח.

שלב 8 – ניתוח סטטיסטי ותיאורי של מוקדי המשיכה

לאחר השלמת איסוף הנתונים ממקורות שונים, עלה הצורך לאחד את כלל שכבות המידע ולבצע ניתוח תיאורי שיאפשר להבין את מאפייני אוכלוסיית מוקדי המשיכה שנבנתה. האתגר המרכזי בשלב זה נבע מכך שהנתונים נאספו במספר תהליכים נפרדים, וכל אחד מהם הדגיש היבט אחר: נתוני פעילות מהרשת החברתית, שיוך לקטגוריות תוכן מתוך תהליך החיפוש הידני, ומאפייני עיסוק ממקור ידע מובנה. ללא איחוד שיטתי של שכבות אלו, לא ניתן היה להפיק תובנות כוללות על גודל האוכלוסייה, פיזור תחומי העניין שלה, ורמות הפעילות הממוצעות של מוקדי המשיכה.

כדי להתמודד עם קושי זה, בוצע תהליך איחוד נתונים שמטרתו ליצור ייצוג אחיד לכל מוקד משיכה, הכולל הן מאפייני פעילות ברשת החברתית והן שיוך לקטגוריית תוכן ולעיסוק עיקרי. לאחר האיחוד בוצעה הסרה מבוקרת של כפילויות, כך שכל חשבון ייצג פעם אחת בלבד, גם אם הופיע במספר

מקורות. על בסיס מאגר מאוחד זה חושבו מדדים סטטיסטיים כלליים, ובהם מספר מוקדי המשיכה הכולל, ממוצע עוקבים, ממוצע נעקבים וממוצע פרסומים, אשר מספקים תמונת מצב כמותית על רמת החשיפה והפעילות של האוכלוסייה הנחקרת.


בנוסף, הופקו שתי טבלאות סיכום מרכזיות: הראשונה מציגה ניתוח לפי קטגוריות תוכן, ומאפשרת להשוות בין תחומים שונים מבחינת היקף מוקדי המשיכה ורמות הפעילות הממוצעות; השנייה מציגה התפלגות עיסוקים, המבוססת על נתוני ידע מובנים, ומאפשרת להבין אילו קבוצות מקצועיות מיוצגות באופן בולט יותר באוכלוסייה. שלב זה חשוב במיוחד משום שהוא מספק תשתית אנליטית להבנת מבנה האוכלוסייה עוד לפני מעבר לניתוחים מתקדמים יותר, כגון בניית רשתות קשרים או ניתוח שיח. באמצעות ניתוח תיאורי זה ניתן לזהות פערי ייצוג, הטיות אפשריות, וקטגוריות דומיננטיות, ולבסס החלטות מושכלות לגבי המשך עיבוד הנתונים ושלבי המחקר הבאים.

=====				
OVERALL STATUS				
=====				
Total POIs	343			
Average Followers	223738			
Average Following	1155			
Average Posts	17623			
=====				
TABLE 1: SUMMARY				
=====				

category	Num_POIs	Avg_Followers	Avg_Following	Avg_Posts
Candidates	67	207858	1238	11248
iranian_activists	63	434124	930	29704
iranian_actors	48	90784	1933	10540
iranian_journalists	45	81837	2265	19989
iranian_writers	31	126667	720	15768
iranian_singers	22	539383	181	3408
iranian_footballers	21	80562	377	36869
iranian_politicians	19	169171	719	16672
iranian_scientists	6	23218	732	13665
iranian_ayatollahs	5	526647	40	17764
iranian_wrestlers	4	29247	351	1339
iranian_economists	4	196875	494	15911
iranian_taekwon	2	1350002	1236	51000
iranian_rappers	2	148550	38	407
iranian_physicians	1	20800	373	1665
iranian_football_players	1	2	42	60
iranian_comedians	1	20300	567	6475
iranian_weightlifters	1	11100	514	8628

Occupation	Count	Percentage
journalist	53	15.5
actor	41	12
politician	40	11.7
writer	38	11.1
singer	32	9.3
association footballer	26	7.6
film director	19	5.5
film actor	17	5
songwriter	16	4.7
composer	14	4.1
television actor	13	3.8
musician	13	3.8
university teacher	12	3.5
screenwriter	12	3.5
poet	12	3.5

הניתוח התיאורי מדגיש פערים בין קטגוריות תוכן שונות וממחיש כי מוקדי המשיכה אינם אוכלוסייה אחידה, אלא מורכבים מקבוצות בעלות רמות חשיפה ופעילות שונות, דבר שנלקח בחשבון בשלבי הסינון והניתוח המאוחרים.



שלב 9 – איסוף קשרי עוקבים ונעקבים לצורך בניית אוכלוסיית מועמדים

בשלב זה החל המעבר ממאגר מוקדי המשיכה אל בניית אוכלוסיית מועמדים, באמצעות איסוף קשרי רשת סביב כל מוקד משיכה. המטרה היא לאסוף, עבור כל מוקד משיכה פעיל, את רשימות העוקבים והרשימות של חשבונות שהוא עוקב אחריהם, ובכך לייצר בסיס נתונים של קשרים המאפשר לזהות משתמשים שמופיעים בסביבת מוקדי המשיכה ובעלי סבירות גבוהה להשתייך לאוכלוסיית היעד.

האתגר המרכזי בשלב זה הוא שמדובר במידע דינמי המוצג בדפי אינטרנט אינטראקטיביים, ללא אפשרות שימוש בממשק רשמי, ולכן נדרש מנגנון איסוף שמסוגל להתמודד עם טעינה הדרגתית של הרשימות, עם שינויי מבנה תצוגה, ועם מגבלות גישה שנועדו למנוע איסוף אוטומטי.

כדי להתמודד עם אתגרים אלה, יושמה שיטת איסוף המבוססת על גלישה מאומתת ודפדוף מבוקר בדפי העוקבים והנעקבים. במקום להסתמך על סלקטור יחיד או על מבנה קשיח שעלול להשתנות, בוצעה הפקה של שמות משתמש מתוך רכיבי הטקסט הגלויים בעמוד, תוך סריקה חוזרת של התוכן לאחר גלילה מדורגת. כך ניתן לאסוף שמות משתמש שמופיעים בפועל בדף גם כאשר הדף נטען חלקית או כאשר מבנה המסמך משתנה. כדי לצמצם חסימות ולשפר יציבות, שולבו השהיות אקראיות בין בקשות, הוגדר מספר גלילות מקסימלי לכל רשימה, והודפסו מדדי התקדמות לצורך בקרה. התוצרים נשמרו כטבלת קשרים שבה כל רשומה מייצגת חיבור בין מוקד משיכה לבין חשבון אחר, עם סימון סוג הקשר האם מדובר בעוקב או בנעקב. בשלב זה בוצעה הרצה מדגמית על מספר מצומצם של מוקדי משיכה לצורך בדיקת תקינות התהליך, לפני הרחבה להרצה מלאה.

שלב זה מהווה נקודת מפתח בפרויקט, משום שהוא מייצר את הנתונים הראשוניים לבניית רשת חברתית ולזיהוי משתמשים מועמדים. מאגר קשרים זה משמש בהמשך לתהליכי סינון, תיוג ואימון מודלים לזיהוי משתמשים השייכים לאוכלוסיית היעד, והוא מאפשר מעבר מעבודה על מוקדי משיכה מוכרים לעבודה על אוכלוסייה רחבה שנגזרת מהקשרים החברתיים סביבם.

בשלב זה בוצע איסוף שיטתי של קשרי עוקבים (followers) ו-נעקבים (following) עבור מוקדי המשיכה (POIs) הפעילים. תחילה הורצה הרצת בדיקה מצומצמת על תת קבוצה קטנה של משתמשים, שמטרתה הייתה לאמת את שיטת האיסוף ולוודא כי ניתן לחלץ שמות משתמש באופן עקבי מתוך ממשק המשתמש של הפלטפורמה. לאחר אימות זה, בוצעה הרצה מלאה על כלל מוקדי המשיכה, תוך שילוב מנגנוני בטיחות ויציבות שנועדו להתמודד עם מגבלות הפלטפורמה וסיכוני חסימה. מנגנונים אלה כללו הגבלת מספר גלילות לכל עמוד, השהיות אקראיות בין בקשות, שמירת התקדמות תקופתית לקובץ, אתחול יזום של סביבת הגלישה לאחר מספר קבוע של משתמשים, וזיהוי חסימה באמצעות ניתוב למסך התחברות. גישה הדרגתית זו אפשרה איסוף רשת קשרים רחבה ואמינה לאורך זמן, תוך צמצום אובדן מידע והבטחת המשכיות תהליך האיסוף גם בהרצות ארוכות.

Target_usernām	Other_usernām	Type
gmziarani	institute of conc	follower
behzadbolour	.at	following
AlimbayevYerlan	__zhang__	follower
la_Biennale	__cfilm	follower
shamaizadeh	__mohsen_	follower
dastournezhad	__tw1tt3r__	follower
SEVDALIZA	__aespect	follower
roozbeh_azar	__dokhtarak	following
NazaninNour	__injaneb96	follower
kngwmn	__mareux__	following
tcsavunma	__mehmetaslan_	follower
nm	__rumi22_	follower
Vahid	__shim_shim	following
Pey_keshavarzi	__thatisgirl__	follower
Pey_keshavarzi	__3pehr__	follower
manizhe	__adilhussain	following
ICHRI	__advanceuk	follower
SEVDALIZA	__aespect	follower
Hossein_kanaani	__agentfootball	follower
SaharZand	__aj_johnstone	following

שלב 9.1 – הפקת מדדי כיסוי ואיכות מאיסוף קשרי העוקבים והנעקבים

לאחר איסוף קשרי העוקבים והנעקבים סביב מוקדי המשיכה, עלה צורך לבצע בקרה כמותית שתאפשר להעריך את איכות האיסוף ואת שיעור הכיסוי שהתקבל בפועל ביחס לגודל החשבונות. האתגר בשלב זה הוא שהאיסוף מבוסס גלילה ומוגבל בזמן ובמספר טעינות, ולכן ייתכן שהרשימות שנאספו אינן מייצגות את מלוא העוקבים/נעקבים של כל מוקד משיכה. כדי להתמודד עם זאת בוצע תהליך סיכום סטטיסטי שממזג בין קובץ הקשרים שנבנה בשלב 9 לבין קובץ המטא-דאטה של מוקדי המשיכה (הכולל את מספר העוקבים והנעקבים הכולל כפי שמופיע בפרופיל). עבור כל מוקד משיכה חושבו מדדים מרכזיים: כמה עוקבים נאספו, כמה נעקבים נאספו, סך הקשרים שנאספו, וכן אחוז הכיסוי לכל אחד מן הרכיבים (עוקבים שנאספו מתוך כלל העוקבים, ונעקבים שנאספו מתוך כלל הנעקבים). בנוסף הופקה סטטיסטיקה כוללת ברמת המאגר (סה"כ קשרים, ממוצע קשרים לכל מוקד משיכה, וזיהוי מוקדי המשיכה בעלי מספר הקשרים הגבוה ביותר), והכול נשמר כקובץ סיכום ייעודי שמאפשר מעקב, השוואה ושיפור איטרטיבי של תהליך האיסוף. שלב זה מהווה שכבת בקרת איכות חיונית לפני המעבר לבניית אוכלוסיית מועמדים, משום שהוא מאפשר לזהות מוקדי משיכה עם כיסוי נמוך במיוחד, להעריך יעילות איסוף, ולבסס החלטות לגבי הרחבת איסוף או סינון מוקדי משיכה בעייתיים.

	Twitter_username	Full_Name	Total_Followers	Followers_Collected	Followers_Percentage	Total_Foll
81	ArashMarkazi	Arash Markazi	122200	44	0.04	
153	livingintehran	Living in Tehran (LiT)	27900	49	0.18	
245	RJahanbegloo	Ramin Jahanbegloo	1951	44	2.26	
145	manoushz	Manoush Zomorodi	35800	45	0.13	
163	NishaBiswal	Nisha Biswal	22700	48	0.21	
...	...	...	...	...	...	...
		...				
	Total_Following	Following_Collected	Following_Percentage	Total_Connections_Collected	Posts_Count	
	2553	55	2.15	99	0	
	98	48	48.98	97	0	
	176	53	30.11	97	0	
	3507	52	1.48	97	0	
	1062	48	4.52	96	0	

שלב 9.2 – איסוף מטא-דאטה עבור מועמדים

(Candidates) והתמודדות עם חסימות ויציבות מערכת

לאחר יצירת מאגר המועמדים מתוך קשרי העוקבים/נעקבים (שלב 9), נדרש להרחיב את בסיס הנתונים מעבר לקשרים עצמם ולאסוף עבור כל מועמד פרטי פרופיל ומדדי פעילות מרכזיים (כגון שם תצוגה, תיאור, מספר עוקבים, מספר נעקבים ומספר פרסומים). הקושי המרכזי בשלב זה הוא שמדובר באוכלוסייה גדולה בהרבה ממוקדי המשיכה, ולכן תהליך איסוף המטא-דאטה הופך לריצה ממושכת ורגישה במיוחד לחסימות, מגבלות קצב, שינויי תצוגה בדפי פרופיל, ותקלות מצטברות של סביבת הגלישה. בנוסף, חלק מהחשבונות אינם זמינים (מושעים/לא קיימים), וחלקם מחזירים מידע חלקי בלבד, מה שעלול לפגוע באיכות מאגר המועמדים ולהקשות על שלבי סיווג וניתוח מאוחרים.

כדי להתמודד עם אתגרים אלה בוצעה ריצה ייעודית לאיסוף מטא-דאטה על בסיס גלישה מאומתת (באמצעות עוגיות התחברות) ותהליך עמיד לתקלות. ראשית, בוצע סינון מוקדם של שמות משתמש לא תקינים לפי כללי הפורמט של הפלטפורמה, כדי להפחית ניסיונות גישה מיותרים. שנית, הוגדר מנגנון "Resume" באמצעות קובץ נקודת ביניים (checkpoint) המאפשר להמשיך את הריצה מאותה נקודה במקרה של עצירה, קריסה או חסימה, ובכך להבטיח שימור תוצאות חלקיות ולמנוע איסוף חוזר. בנוסף, שולבו מנגנוני אנטי חסימה: השהיות אקראיות קצרות בין משתמשים, הפסקות ארוכות במרווחים קבועים ("human-like behavior"), ואתחול דפדפן מחזורי לשמירה על יציבות לאורך זמן. לבסוף, הוגדרו מנגנוני זיהוי והתאוששות מחסימה כגון ניתוב למסך התחברות, הודעות rate limit או עמוד קצר מדי, ובמצבים אלו בוצעה עצירה מבוקרת הכוללת שמירת נתונים, המתנה ממושכת וחזרה לאיסוף. כדי להבטיח איכות נתונים, הוגדרה ולידציה מינימלית כך שרשומה נשמרת רק אם התקבלו לפחות שניים מתוך שלושת השדות המרכזיים (עוקבים/נעקבים/פרסומים). תוצר השלב הוא קובץ מטא-דאטה מרוכז עבור אוכלוסיית המועמדים, המשמש בסיס לשלבים הבאים של סינון, תיוג, והפעלת מודלים לזיהוי שייכות לאוכלוסיית היעד.

שלב 11 – ניתוח סטטיסטי תיאורי של משתמשי המטרה

הפוטנציאליים

בשלב זה בוצע ניתוח סטטיסטי תיאורי מקיף של אוכלוסיית משתמשי המטרה הפוטנציאליים (Candidates), אשר נאספו בשלבים הקודמים מתוך רשת הקשרים של ה-POIs-מטרת שלב זה הייתה לאפיין באופן כמותי את מבנה האוכלוסייה, לבחון את איכות ושלמות הנתונים, ולהבין את דפוסי הפעילות וההשפעה הדיגיטלית של המשתמשים טרם מעבר לשלבים מתקדמים יותר כגון סינון, דירוג או בניית מודל חיזוי.

ניקוי והכנת הנתונים

השלב הראשון כלל תהליך Data Cleaning והמרת טיפוסים. (Type Casting) עמודות מספריות כגון מספר עוקבים (followers count), מספר נעקבים (following count) ומספר פרסומים (statuses_count) הומרו לטיפוסים נומריים, תוך טיפול בערכים חריגים או לא תקינים שהומרו ל-NaN. בנוסף, עמודת תאריך יצירת החשבון, (created_at) כאשר הייתה זמינה, הומרה לפורמט תאריך תקני, ומתוכה חושב משתנה חדש – גיל החשבון בשנים (account_age_years). חישוב זה אפשר לבחון את הוותק הדיגיטלי של המשתמשים ולהצליבו עם רמות פעילות והשפעה.

תהליך זה היה קריטי על מנת להבטיח עקביות נתונים, למנוע שגיאות חישוביות בהמשך, ולאפשר חישוב מדדים סטטיסטיים אמינים

חישוב מדדים סטטיסטיים מרכזיים

לאחר ניקוי הנתונים, חושבו מדדים תיאוריים מרכזיים ברמת כלל האוכלוסייה:

- מספר המשתמשים הכולל שנאספו
 - שיעור המשתמשים עם נתונים מלאים (Data Completeness Rate)
 - ממוצע וחציון של מספר העוקבים
 - ממוצע וחציון של מספר הנעקבים
 - ממוצע וחציון של מספר הפרסומים
 - ממוצע וחציון של גיל החשבון (כאשר הנתון קיים)
- השוואה בין ממוצע לחציון אפשרה לזהות האם קיימת הטיה בהתפלגות (Skewness). לדוגמה, פער משמעותי בין הממוצע לחציון במספר העוקבים מעיד על קיומם של משתמשים בודדים בעלי השפעה גבוהה במיוחד, (High-Influence Users) היוצרים זנב ימני ארוך בהתפלגות – תופעה נפוצה ברשתות חברתיות.

ניתוח התפלגויות וויזואליזציה

לצורך הבנה מעמיקה יותר של מבנה האוכלוסייה, הופקו היסטוגרמות עבור ארבעה משתנים מרכזיים:

1. התפלגות מספר העוקבים
2. התפלגות מספר הנעקבים
3. התפלגות מספר הפרסומים
4. התפלגות גיל החשבון

בכל היסטוגרמה סומנו גם הממוצע והחציון, במטרה להמחיש את מבנה ההתפלגות ואת רמת האסימטריה שלה. ניתוח ויזואלי זה מאפשר לזהות:

- ריכוזיות ערכים נמוכים לעומת ערכים קיצוניים
- קיומם של משתמשים חריגים (Outliers)
- מבנה זנב כבד (Heavy Tail)
- שונות גבוהה בין משתמשים

תוצאות הניתוח מצביעות בדרך כלל על מבנה היררכי אופייני לרשתות חברתיות, שבו רוב המשתמשים מחזיקים במספר עוקבים נמוך עד בינוני, בעוד שמיעוט קטן מחזיק במספר עוקבים גבוה במיוחד.

ניתוח משתמשים מובילים

בנוסף לניתוח הכללי, בוצע זיהוי של:


- עשרת המשתמשים בעלי מספר העוקבים הגבוה ביותר
 - עשרת המשתמשים הפעילים ביותר מבחינת מספר פרסומים
- ניתוח זה מאפשר לזהות מוקדי השפעה פוטנציאליים בתוך אוכלוסיית המועמדים, ולהעריך את מידת המרכזיות (Centrality) או הדומיננטיות של משתמשים מסוימים ברשת.


תרומת השלב למחקר

שלב 11 מהווה שלב קריטי בהבנה מבנית של הדאטה לפני יישום אלגוריתמים מתקדמים. באמצעות ניתוח סטטיסטי תיאורי:

- מתקבלת תמונה ברורה של איכות ושלמות הנתונים
 - מזהים דפוסי פעילות והשפעה דיגיטלית
 - ניתן לקבוע ספים (Thresholds) להמשך סינון
 - ניתן לזהות חריגים שדורשים טיפול מיוחד
 - מתקבל בסיס אמפירי להנחות עבודה בשלבים הבאים
- במילים אחרות, שלב זה מייצר את התשתית הכמותית שעליה ניתן לבסס החלטות מחקריות והנדסיות בהמשך הפרויקט.

Stage 11: Statistical Distribution Analysis - Candidate Users





Metric	Value
Total unique users	946
Users with complete data	718
Data completeness (%)	75.9
Average posts (statuses_count)	1088
Median posts	94
Average followers	972
Median followers	68
Average following	878
Median following	276
Average account age (years)	5.5
Median account age (years)	3.8

שלב 12 – יצירת מערך תיוג ידני ראשוני (Manual Ground Truth – Iteration 1)

שלב זה מסמן מעבר מתהליך איסוף והעשרת נתונים לתהליך בניית **אמת מידה אנושית (Ground Truth)**, אשר תשמש בסיס להערכת איכות ולמידה מונחית בהמשך הפרויקט. בניגוד לשלבים קודמים שהתמקדו באיסוף אוטומטי, חישובים סטטיסטיים או ניתוח רשת, שלב זה מבוסס במכוון על **תיוג אנושי מלא**, ללא אוטומציה וללא שימוש במודלים.

מטרת השלב היא ליצור מדגם מייצג מתוך אוכלוסיית המועמדים (Candidates) ולהכינו לתהליך תיוג ידני שיטתי, ועקבי.

1. דגימה אקראית מבוקרת וניתנת לשחזור

מתוך כלל אוכלוסיית המועמדים שנאספה בשלבים הקודמים, נבחר מדגם אקראי בגודל קבוע (לדוגמה: 100 משתמשים). הבחירה בוצעה באמצעות אלגוריתם דגימה אקראית תוך שימוש ב־ **Random Seed קבוע**.

המשמעות המתודולוגית של שימוש ב־ Seed קבוע היא:

- הבטחת שחזור מלא של המדגם בכל הרצה עתידית
- שקיפות מתודולוגית
- יכולת לבצע השוואות בין איטרציות
- מניעת הטיות מקריות בבחירת המדגם

גישה זו תואמת עקרונות מחקר אמפירי במדעי הנתונים, שבהם יכולת השחזור של הניסוי היא תנאי בסיסי לתקפות מחקרית.

2. הגדרת סכמת התיוג (Labeling Schema)

למדגם שנבחר נוספו עמודות תיוג ריקות, המהוות את סכמת הסיווג האנושית של הפרויקט. סכמת התיוג הוגדרה מראש בהתאם למטרות המחקר וכוללת ארבעה ממדים:

target population

סיווג המשתמש לאחת מהקטגוריות:

- target
- non_target
- unknown

שדה זה נועד לקבוע האם המשתמש משתייך לאוכלוסיית היעד של המחקר.

locals_vs_diaspora

סיווג לפי שיוך גיאוגרפי-חברתי:

- local
- diaspora
- unknown

שדה זה מאפשר להבחין בין משתמשים מקומיים לבין משתמשים מהתפוצה (Diaspora), ניתוח חשוב בהקשר המחקרי של איראן.

person_vs_organization

סיווג לפי סוג ישות:

- person
- organization
- unknown

שדה זה מאפשר להבדיל בין חשבונות של אנשים פרטיים לבין גופים מוסדיים, כלי תקשורת, עמותות וכדומה.

comments

שדה טקסט חופשי המאפשר למתייג להוסיף:

- נימוקים
- הסתייגויות
- הערות על עמימות
- מידע איכותני רלוונטי

שדה זה חשוב במיוחד לזיהוי מקרים גבוליים ולניתוח איכותי בהמשך.

3. הפרדת קבצים וניהול איטרציות

המדגם נשמר במספר קבצים נפרדים תחת תיקיית Classification, ביניהם:

- קובץ מרכזי הכולל את כל העמודות
- קבצים ייעודיים לכל ממד סיווג

מבנה זה מאפשר:

- עבודה מודולרית
- תיוג במקביל על ידי מספר מתייגים
- בקרה (Inter-Annotator Agreement) בעתיד
- ניהול איטרציות תיוג בצורה מסודרת

שלב זה הוגדר במפורש כ- **Iteration 1**, מתוך הבנה שתהליך תיוג הוא תהליך איטרטיבי שבו ניתן לשפר הגדרות, לאחד קריטריונים ולהפחית עמימות לאחר סקירה ראשונית של התוצאות.

4. חשיבות מחקרית של השלב

שלב זה הוא קריטי מבחינה מתודולוגית משום שהוא:

- יוצר מערך נתונים מתויג ראשון שישמש כבסיס לאימון מודלים
- מאפשר בדיקת איכות התיוג והבהרת קריטריונים
- מייצר Benchmark אנושי להשוואה מול חיזויים עתידיים
- מאפשר ניתוח הטיות פוטנציאליות מוקדם
- מספק תובנות איכותניות שלא ניתנות לזיהוי אוטומטי

במילים אחרות, שלב זה מייצר את התשתית שעליה ניתן לבנות שלבי למידה מונחית והערכת ביצועים בהמשך הפרויקט.

5. הקשר לאיטרציות עתידיות

מערך התיוג הידני שנוצר באיטרציה הראשונה ישמש לצורך:

- אימון מודל סיווג ראשוני
- זיהוי משתמשים עם רמת חוסר ודאות גבוהה
- בחירת דגימות נוספות לתיוג באיטרציה 2
- שיפור הדרגתי של ביצועי המודל

גישה זו תואמת מתודולוגיית **Active Learning / Iterative Annotation**, שבה תהליך התיוג והממודל מזינים זה את זה באופן מחזורי.

טבלה של איטרציה ראשונה ויישום כל מה שתואר על שלב 12:

Username	Display_name	Description	Followers_count	Following_count	Statuses_count	Verified	Created_at
abhistoria	Ahab Bdaiwi	Assistant Profess	33500	937	4281	False	July 2017
dinken	Ajmal Hussain A	It's okay to get r	379	529	961	False	November 20
alijan2056	Ali		8	73	4	False	November 20
addyperry20	LilyPerry	Okay but... I'm ki	510	3722	1567	False	May 2025
_uselessgothdm	Definitely Not a	@ useless_goth_	19	124	36	False	June 2020
ahmad76905530	ahmad		40	706	8	False	January 2023
am2002rmost	Amir		14	252	0	False	March 2023
_nam11	Nathan	@charltonlive c	4887	2796		False	May 2010
afkari_saeed	سعید افکاری	آزادی	68900	78	1273	False	August 2020
aliceparkny	Alice Park	Health and med	13400	469	4818	False	March 2009
abkoga	A.B. Koga	SFF Author on S	643	633	1953	False	September 2
_sgtslaughter	SGT SLAUGHTER	WWE Hall of Fan	107700	107	6124	False	September 2
aleaguewomen	Ninja A-League	Official account	28600	2092	1356	False	August 2012
_hannahritchie	Hannah Ritchie	Deputy Editor @	79800	1337	7978	False	July 2014
afterpay_au	Afterpay	Don't just pay la	5939	521	964	False	July 2014
_sky_tw	spinoss		1	19	0	False	January 2023
adnanime	Animation Digits	Evangelion, Uter	385900	676	1315	False	September 2
ahwazmedia	سن راضي الأحواز	#..2الأحواز وطني	5884	415	8467	False	April 2012
allipayam	Hani Allipayam		36	19	1	False	November 20
ajbends	big boy syntheti	@issues // @ba	42300	1286	1350	False	December 20
alisaberi1987	Alex	All religions are	469	1634	633	False	October 202
altaf_awan12	Altaf K Awan	Consultant Panc	1054	451	1803	False	November 20
aliansari84	Ali Ansari	Ph.D. graduate in	742	1928	1334	False	December 20
alimotie1318	Parsi	Iran, land of Arya	160	753	4588	False	June 2025
aesdigitallyart	Aes Digitally Art	Greetings! I'm Se	29	333	32	False	November 20

	Profile_image_url	Profile_banner	Target_population	Locals_vs_diaspora	Person_vs_organization	Comments	Description_En	Display_name
ab	https://pbs.twimg		2		1		Assistant Profess	Ahab Bdai
	https://pbs.twimg		0		1		It's okay to get r	Ajmal Hus
	https://pbs.twimg		2		1			Ali
	https://pbs.twimg		0		1		Okay but... I'm ki	LilyPerry
	https://pbs.twimg		0		2		@ useless_goth_	Definitely
	https://pbs.twimg		2		1			ahmad
	https://pbs.twimg		2		1			Amir
	https://pbs.twimg		0		1		@charltonlive c	Nathan
	https://pbs.twimg		1	1	1	translate the sta	freedom	Saeed Afk
	https://pbs.twimg		0		1		Health and med	Alice Park
	https://pbs.twimg		0		1		SFF Author on S	A.B. Koga
	https://pbs.twimg		0		1		WWE Hall of Fan	SGT SLAU
	https://pbs.twimg		0		0		Official account	Ninja A-Le
	https://pbs.twimg		0		1		Deputy Editor @	Hannah Ri
	https://pbs.twimg		0		0		Don't just pay la	Afterpay
	https://pbs.twimg		0		2			spinoss
	https://pbs.twimg		0		0		Evangelion, Uter	Animation

Stage 12.1 – Manual Labeling Analysis (Iteration 1)

לאחר השלמת התיג הידני של 100 משתמשים שנדגמו באופן אקראי, בוצע ניתוח סטטיסטי ראשוני של שלוש קטגוריות הסיווג:


- Target Population
- Locals vs Diaspora
- Person vs Organization

בשלב הראשון נבדקה שלמות התיג (labeling completeness) על מנת לוודא כי כל המשתמשים סווגו באופן מלא בכל שלושת המימדים. לאחר מכן חושבה התפלגות תדירויות ואחוזים עבור כל מחלקה בכל קטגוריה.

בנוסף, בוצע ניתוח חוצה קטגוריות (cross-tabulation) לבחינת הקשרים בין:

- השתייכות לקבוצת יעד לבין מיקום גאוגרפי (מקומי/תפוצה)
- השתייכות לקבוצת יעד לבין סוג החשבון (אדם/ארגון)

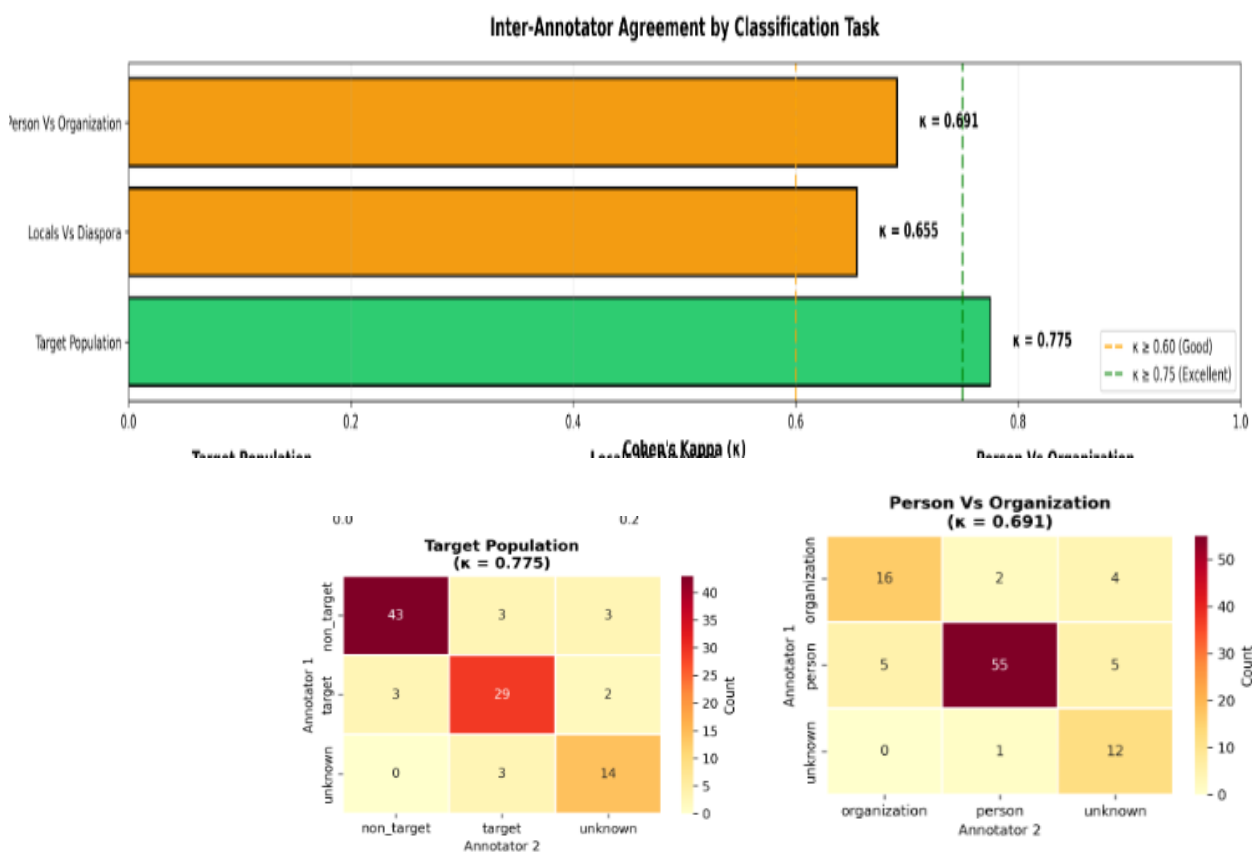
ניתוח זה מספק בסיס אמפירי להבנת מאפייני קבוצת היעד, ומהווה תשתית לאימון מודל סיווג באיטרציות הבאות.





Stage 12.2 – Double Annotation & Inter-Annotator Agreement

בשלב זה ביצענו תהליך **תיוג כפול (Double Annotation)** על מדגם המשתמשים שתויג באיטרציה 1, במטרה להעריך את **אמינות התיוג** ואת מידת העקביות בין מתייגים שונים. לצורך חלוקה מאוזנת של עבודה בין מספר מתייגים, כל משתמש הוקצה לזוג מתייגים בשיטת **Round Robin** על פני שישה מתייגים, (A1–A6) כך שכל מתייג משתתף במספר זוגות לאורך המדגם. לאחר ביצוע שני תיוגים לכל משימה (Target Population, Locals vs Diaspora, Person vs Organization), חושב שיעור ההסכמה הישיר (Percent Agreement) וכן מדד **Cohen's Kappa (κ)**, שמודד הסכמה תוך תיקון להסכמה אקראית. בנוסף, עבור מקרים של אי הסכמה יושמה אסטרטגיית **יישוב מחלוקות** המדמה עבודה אמיתית: חלק מהמחלוקות נפתרו בדיון בין הזוג המקורי, חלק הוסלמו לזוג מתייגים בכיר יותר, ומיעוט הוכרע בהחלטת גורם מכריע. תוצר השלב הוא דו"ח מדדים שמאפשר לקבוע האם התיוג מספיק עקבי כדי לשמש כ Ground Truth-לאימון מודלים באיטרציות הבאות, וכן מצביע על משימות שבהן קיימת עמימות גבוהה יותר, לרוב locals_vs_diaspora ועל הצורך לחדד הנחיות תיוג.

Double Annotation Analysis - Inter-Annotator Agreement





בתרשים העליון מוצג מדד **Cohen's Kappa (κ)** עבור שלוש משימות הסיווג: **Target Population**, **Locals vs Diaspora** ו-**Person vs Organization**. ניתן לראות כי רמת ההסכמה הגבוהה ביותר התקבלה במשימת **Target Population** עם $\kappa = 0.775$, על המעידה על הסכמה גבוהה מאוד) קרובה לקטגוריית "Excellent". במשימת **Person vs Organization** התקבל, $\kappa = 0.691$, המעיד על הסכמה טובה, ואילו במשימת **Locals vs Diaspora** התקבל – $\kappa = 0.655$ – רמת הסכמה בינונית-טובה אך נמוכה יותר, דבר המצביע על מורכבות ואי בהירות יחסית בהבחנה בין מקומיים לתפוצות הקווים המקווקווים בגרף מסמנים את ספי האיכות. ($0.60 = \text{Good}$, $0.75 = \text{Excellent}$).

מטריצות הבלבול (Confusion Matrices) מציגות את התפלגות ההסכמות והאי הסכמות בין שני חברי הצוות בכל משימה. הערכים שעל האלכסון המרכזי מייצגים מקרים של הסכמה מלאה. לדוגמה: 43 ב- non_target ו-29 ב- target במשימת Target Population, בעוד הערכים מחוץ לאלכסון מייצגים אי התאמות. ניתן לראות כי ברוב המשימות עיקר הערכים מרוכזים על האלכסון, מה שמעיד על עקביות גבוהה בין חברי הצוות.


בתיבת הסטטיסטיקה המסכמת מוצגים נתוני העל: 300 אנוטציות בסך הכול (100 משתמשים $\times$ 3 משימות), 6 חברי הצוות ו-12 צמדי עבודה שונים. שיעורי ההסכמה באחוזים עומדים על 86% ב- Target Population (77% ב- Locals vs Diaspora ו-83% ב- Person vs Organization). ממוצע ה- κ הוא 0.707, עם מינימום 0.655 ומקסימום 0.775 – נתונים המצביעים על רמת מהימנות טובה עד גבוהה בכלל המשימות, כאשר משימת ה- Locals vs Diaspora היא המאתגרת ביותר מבחינת אחידות הסיווג.

שלב 13: פורמליזציה של כללי התיוג ובניית מסגרת החלטה שיטתית

בשלב זה התבקשנו לתרגם את תהליך קבלת ההחלטות שביצעו חברי הצוות בזמן התיוג הידני למסגרת פורמלית, ברורה ומחזורית. לצורך כך בנינו דיאגרמות זרימה (Flowcharts) המתארות בצורה היררכית את סדר השאלות והבדיקות שעליהן מתבססת כל החלטת סיווג בשלוש משימות התיוג: **Target Population**, **Locals vs Diaspora** ו-**Person vs Organization**. הדיאגרמות נבנו לאחר ניתוח רטרוספקטיבי של האופן שבו קיבלנו החלטות בפועל במהלך התיוג – אילו אינדיקציות בדקנו קודם (מיקום, ביוגרפיה, שם משתמש, תמונת פרופיל), כיצד הכרענו במקרים גבוליים, ואילו תנאים הובילו לסיווג כ- UNKNOWN. מתוך הדיונים בצוות זיהינו תבניות חוזרות של קבלת החלטות, ארגנו אותן כרצף לוגי של שאלות כן/לא, והפכנו אותן לדיאגרמות ברורות הממחישות את מסלול ההכרעה עד לתוצאה הסופית. כך יצרנו מערכת כללים עקבית שמבטיחה אחידות בין חברי הצוות, מצמצמת עמימות, ומבססת את תהליך התיוג כהליך מתודולוגי מובנה ולא אינטואיטיבי בלבד.

Locals VS Diaspora


בדיאגרמה זו מוצג תהליך קבלת ההחלטות לצורך הבחנה בין משתמשים המתגוררים באיראן לבין משתמשים החיים מחוץ לאיראן. תחילה נבדק האם המשתמש הוגדר בשלב הקודם כשייך לאוכלוסיית היעד. אם אינו שייך, אין צורך להמשיך בסיווג זה. אם הוא כן שייך, נבדק האם מצוין מיקום בפרופיל. כאשר קיים מיקום ברור, נבחנת השאלה האם הוא מצביע על מגורים באיראן או במדינה אחרת. אם לא מצוין מיקום, או שהמיקום אינו חד משמעי, ההחלטה מתבססת על הביוגרפיה ועל תוכן הציוצים, כגון אזכורים של חיי יומיום באיראן, הקשרים מקומיים או רמזים לשוניים. על בסיס כלל האינדיקציות מתקבלת הכרעה בין מקומי, תפוצות או לא ידוע במקרה של מידע חלקי או סותר.



Target Population


בדיאגרמה זו מוצג תהליך ההכרעה בשאלה האם המשתמש משתייך לאוכלוסיית היעד. תחילה נבדק האם מצוין מיקום בפרופיל והאם הוא מצביע באופן מפורש על איראן. אם אין מיקום ברור, נבדקת הביוגרפיה לאיתור אזכורים לזהות איראנית, השתייכות תרבותית או מאפיינים רלוונטיים נוספים. בהמשך נבחן תוכן הציוצים כדי לאתר עדויות לשוניות או תוכניות המעידות על זיקה ממשית לאיראן.

אם קיימות אינדיקציות עקביות וברורות, המשתמש מסווג כחלק מאוכלוסיית היעד. בהיעדר אינדיקציה כלשהי יסווג כלא יעד, ובמקרים של מידע חלקי או סתירות יסווג כלא ידוע.



Person VS Organization

דיאגרמה זו מתארת את שלבי הסיווג בין חשבון של אדם פרטי לבין חשבון של ארגון. תהליך ההכרעה מתחיל בבחינת שם המשתמש ושם התצוגה, במטרה לזהות מילות מפתח המעידות על גוף רשמי או מוסדי. בהמשך נבדקת תמונת הפרופיל כדי להבחין בין צילום אישי לבין לוגו או סמל מסחרי. לאחר מכן נבחנת הביוגרפיה, ונבדק האם היא מתארת תפקידים אישיים ומקצועיים או פעילות של מוסד, כלי תקשורת או ארגון. לבסוף נבחן תוכן הציוצים, כדי לזהות האם מדובר בשיח אישי ודעות פרטיות או בפרסום רשמי ושיווקי. שילוב כלל הסימנים מוביל לסיווג כחשבון של אדם פרטי, ארגון, או לא ידוע כאשר אין די מידע להכרעה ברורה.



שלב 14: מסגרת ניסויים אקדמית ללמידה אקטיבית והכנת ייצוגים למודלי סיווג

בשלב 14 המטרה הייתה להפוך את תהליך הסיווג הידני לתהליך מחקרי מדיד: להגדיר שלוש משימות סיווג ברורות (אוכלוסיית יעד, מקומיים/תפוצות, אדם/ארגון), לבנות ייצוגים מספריים עקביים מתוך הטקסט והמטא דאטה, ולהריץ "גריד" ניסויים רחב שמאפשר להשוות באופן הוגן בין שילובי מאפיינים, אלגוריתמים ושיטות ולידציה. הדגש בשלב הזה הוא לא "לבחור מודל מהר", אלא לייצר השוואה שיטתית ומבוססת שממנה אפשר להסיק מה עובד טוב יותר עבור כל משימה, ובאיזה תנאים (דו מחלקתי מול רב מחלקתי, מאוזן מול לא מאוזן).

בשלב הראשון בתוך שלב 14 הוגדרו שלוש משימות הסיווג לפי הנתונים המתויגים מאיטרציה 1, כולל מיפוי עקבי של התוויות לערכים אחידים (target/non_target/unknown; person/organization/unknown). משימת locals_vs_diaspora היא רלוונטית רק עבור משתמשים שכבר סווגו כ-target, ולכן הנתונים למשימה זו מסוננים מראש ומנותקים מכל משתמש שאינו יעד. זה מונע "רעש" לוגי בניסוי ומיישר קו עם ההנחיות – קודם קובעים יעד, ורק אחר כך מחליטים מקומי/תפוצה.

לאחר מכן בוצע שלב תרגום טקסטים לאנגלית (שלב 1.5) כדי לאפשר הפקת מאפייני TF-IDF בצורה יציבה ואחידה. מאחר שחלק מה-bio- וה-display_name כתובים בפרסית או בשפות נוספות, מודל TF-IDF באנגלית עלול לפרק טקסט לא אנגלי בצורה לא עקבית ולהחליש את המאפיינים. לכן תורגמו השדות display_name וdescription לעמודות display_name_en וdescription_en תוך טיפול במקרים של שדות ריקים/חסרים, ניסיון חוזר במקרה של שגיאות, ושמירה על הטקסט המקורי אם התרגום נכשל. בצורה הזו מתקבל בסיס טקסטואלי אחיד שמאפשר השוואה הוגנת בין ניסויים ולא "מעניש" משתמשים רק בגלל שפת הכתיבה.

בשלב הנדסת המאפיינים (שלב 2) הופקו מאפיינים טקסטואליים ומספריים. בצד הטקסטואלי הופקו ייצוגי TF-IDF באנגלית עבור description_en, עבור display_name_en, ועבור שילוב של שניהם (combined_text_en), כולל שימוש ב unigram+bigrams, סינון מונחים נדירים מדי או נפוצים מדי, והסרת מילות עצירה באנגלית כדי לשפר איכות אותות לשפה זו. בצד המספרי הופקו מאפיינים בסיסיים שמייצגים התנהגות ופרופיל: מספר עוקבים, מספר נעקבים, מספר פוסטים, יחס עוקבים/נעקבים, ואורך bio (באנגלית לאחר תרגום). מאחר והמאפיינים המספריים נמצאים בסקאלות שונות, בוצעה סטנדרטיזציה (StandardScaler) כדי למנוע ממאפיין עם סדר גודל גדול "לדרוס" אחרים. לבסוף נבנו מטריצות משולבות שמחברות טקסט+מספרים, כדי לבדוק האם שילוב מידע תוכני עם התנהגות חשבונית משפר את הביצועים.

לאחר שהוגדרו הנתונים והמאפיינים, נבנתה מסגרת ניסויים מלאה (Full Grid) שמייצרת בנצ'מרק אקדמי: עבור כל אחת משלוש המשימות מורצים ניסויים על פני סט מאפיינים רחב (7 סטים של TF-IDF ו-5 מאפיינים מספריים בודדים), (על פני שישה אלגוריתמים שונים (Logistic Regression, Decision Tree, Random Forest, SVM, XGBoost, AdaBoost) ועל פני שתי אסטרטגיות ולידציה (K-Fold עם K=5) LOOCV) בנוסף, עבור כל שילוב נבדקו ארבע וריאציות שמכסות שני צירים חשובים (דו מחלקתי מול רב מחלקתי) כאשר בדו מחלקתי מסירים את unknown כדי לקבל בעיה בינארית נקייה, (ומאוזן מול לא מאוזן) כאשר בגרסה המאוזנת מבצעים downsampling לכל המחלקות לגודל המחלקה הקטנה ביותר, כדי למנוע הטיה חזקה לכיוון מחלקה דומיננטית. (כל התוצאות נכתבות לקובץ experiments_results.csv באותו פורמט קבוע, כך שכל שורה היא ניסוי אחד וכוללת גם פרטי תצורה (משימה/אלגוריתם/מאפיינים/ולידציה/איזון) וגם מדדי ביצוע (Accuracy, Precision, Recall, F1) ובמקרה בינארי גם ROC-AUC).

כדי להבטיח מדידה הוגנת במיוחד במדדי ROC-AUC, המסגרת מחשבת "ציון רציף" כאשר הדבר אפשרי: אם האלגוריתם יודע להחזיר הסתברויות (predict_proba) משתמשים בהן, ואם לא – משתמשים ב decision_function. כך נשמרת עקביות במדידה בין אלגוריתמים שונים, וה AUC לא

נשען על תחזיות קשיחות בלבד. בנוסף, במקום להסתמך על פונקציות חיצוניות שמבצעות אימון כפול או לא שקוף בכל fold, התהליך בנוי כלולאה ידנית שבה בכל פיצול מאמנים פעם אחת ומפיקים תחזית, מה שמייצר רפרנס ברור, יציב ושחזורי.

בחלק האחרון בוצע תיקון תפעולי חשוב בקובץ הניסויים: במקום "NUM_only" (שילוב מספרי אחד כללי), הוחלט לנתח כל מאפיין מספרי בנפרד, כדי להבין מה התרומה של כל אות מספרי בפני עצמו. לכן נמחקו שורות "NUM_only" מקובץ התוצאות, ובוצעה הרצה מחדש של כל הגריד עבור חמשת המאפיינים המספריים הבודדים, (followers, following, statuses, ratio, bio_len) כולל אותה לוגיקה של משימות/אלגוריתמים/ולידציה/איזון/דו מחלקתי מול רב מחלקתי. כך מתקבלת תמונה הרבה יותר חדה: האם למשל יחס עוקבים/נעקבים הוא אות משמעותי יותר ממספר פוסטים, והאם אורך bio תורם בכלל לסיווג – בלי שהמאפיינים המספריים "יתערבבו" בתוך חבילה אחת.

הגדרת מרחב הניסויים

לכל אחת משלוש המשימות הורצו ניסויים על פני:

- 12 סטים של פיצ'רים
7 ייצוגי TF-IDF שונים (description, username, full name) ושילובים ביניהם
5 פיצ'רים נומריים בודדים (followers, following, statuses, ratio, bio length)
- 6 אלגוריתמים:
Logistic Regression
Decision Tree
Random Forest
SVM
XGBoost
AdaBoost
- 2 אסטרטגיות ולידציה:
K-Fold Cross Validation (K=5)
Leave-One-Out Cross Validation
- 4 וריאציות לכל תצורה:
בינארי / רב-מחלקתי
מאוזן / לא מאוזן

בכך התקבל מרחב ניסויים רחב ומובנה, שמאפשר השוואה שיטתית ומבוססת בין כל שילובי ההגדרות האפשריים.

הנדסת תכונות

הפיצ'רים חולקו לשני סוגים עיקריים:

1. תכונות טקסטואליות – ייצוג TF-IDF עם unigram ו bigram סינון לפי שכיחות, והגבלת מספר פיצ'רים.
 2. תכונות נומריות – מדדים מבניים של החשבון כגון מספר עוקבים, יחס עוקבים לעוקבים אחרים, אורך ביוגרפיה ועוד, כאשר כל פיצ'ר נורמל בנפרד באמצעות StandardScaler.
- בנוסף להרצות משולבות של טקסט + נומרי, הורצו גם ניסויים שבהם כל פיצ'ר נומרי נבחן בנפרד, כדי להעריך את תרומתו העצמאית.

טיפול באיזון נתונים

לכל משימה נבחנו שני מצבים:

- מצב טבעי (התפלגות מקורית)
 - מצב מאוזן (Downsampling) למחלקה הקטנה ביותר)
- באופן זה ניתן היה לבחון האם שיפור בביצועים נובע מהתפלגות נתונים לא מאוזנת או מיכולת אמיתית של המודל להבחין בין הקטגוריות.

מדדי הערכה

לכל ניסוי חושבו המדדים הבאים:

- Accuracy
 - Precision
 - Recall
 - F1-score
 - ROC-AUC בבעיות בינאריות
- התוצאות נשמרו בקובץ experiments_results.csv כאשר כל שורה מייצגת ניסוי אחד עם תיעוד מלא של:
- המשימה, מספר המחלקות, גודל כל מחלקה, סוג הולידציה, האלגוריתם, סט הפיצ'רים, איזון הנתונים וכל המדדים המחושבים.

מבנה טבלת התוצאות

הטבלה המוצגת כוללת:

- פרטי הניסוי (iteration, target column, #classes)
- התפלגות מחלקות בפועל
- סוג הולידציה וערך K
- שם האלגוריתם
- סט הפיצ'רים
- מספר הפיצ'רים בפועל
- האם בוצע איזון נתונים
- מדדי ביצועים מלאים

תרומת השלב למחקר

שלב זה מהווה את התשתית האנליטית של תהליך ה-Active Learning. במקום לבחור מודל בצורה אינטואיטיבית, נבנתה מסגרת השוואתית רחבה שמאפשרת:

- זיהוי המודל היציב ביותר
- זיהוי סט הפיצ'רים היעיל ביותר
- בחינת רגישות לאיזון נתונים
- השוואה בין הולידציות שונות
- קבלת החלטה מושכלת לגבי המודל שירץ על הדאטה הלא מתויג באיטרציה הבאה

זהו שלב קריטי שמבטיח שהמשך התהליך יתבסס על בחירה אמפירית ולא על הנחות.

Iteration	Target_column	#classes	#class_0	#class_1	#class_2	Min_class_size	Training_type
1	target_population	3	50	33	17	17	KFold
1	target_population	3	17	17	17	17	KFold
1	target_population	2	50	33	0	33	KFold
1	target_population	2	33	33	0	33	KFold
1	target_population	3	50	33	17	17	LOOCV
1	target_population	3	17	17	17	17	LOOCV
1	target_population	2	50	33	0	33	LOOCV
1	target_population	2	33	33	0	33	LOOCV
1	target_population	3	50	33	17	17	KFold
1	target_population	3	17	17	17	17	KFold
1	target_population	2	50	33	0	33	KFold
1	target_population	2	33	33	0	33	KFold
1	target_population	3	50	33	17	17	LOOCV
1	target_population	3	17	17	17	17	LOOCV
1	target_population	2	50	33	0	33	LOOCV
1	target_population	2	33	33	0	33	LOOCV

שלב 15 – תחילת תהליך למידה אקטיבית (Active Learning) איטרציה ראשונה

שלב 15 מהווה המשך ישיר לשלב 14, שבו בוצעה בחירה שיטתית של מודלים, ייצוגי פיצ'רים ואלגוריתמים באמצעות גריד ניסויים רחב. לאחר שבשלב 14 זוהו הקונפיגורציות החזקות ביותר לכל אחת משלוש משימות הסיווג, בשלב זה מיושמת לראשונה למידה אקטיבית מבוססת אי-ודאות. בתחילת התהליך נטענת כלל אוכלוסיית המועמדים, וממנה מוסרים המשתמשים שכבר תויגו ידנית באיטרציה הראשונה. כך מתקבלת קבוצת משתמשים לא מתויגים, אשר מהווה את מאגר היעד לבחירה חכמה של דגימות חדשות לתיג. לאחר מכן מוגדרות שלוש משימות סיווג עצמאיות – target – population, locals_vs_diaspora ו-person_vs_organization כאשר לכל משימה נקבע מודל קבוע וייצוג פיצ'רים בהתאם לתוצאות שלב 14. עבור כל משימה מאומן המודל על הדאטה המתויג הקיים, מבוצעת תחזית על כלל המשתמשים הלא מתויגים, ומחושב ציון אי-ודאות לכל דוגמה על בסיס רמת הביטחון של המודל. לבסוף נבחרים 100 המשתמשים בעלי אי-הודאות הגבוהה ביותר לצורך תיוג ידני באיטרציה הבאה, ובכך מושלם מחזור הלמידה האקטיבית הראשון.

```

iteration_1_agreement_report.csv
iteration_1_double_annotations.csv
iteration_1_manual_labeling.csv
iteration_1_unlabeled_users_prediction...
iteration_1_unlabeled_users_prediction...
iteration_2_manual_labels_person_vs_o...
iteration_2_manual_labels_target_pop...
iteration_2_unlabeled_users_prediction...
iteration_2_unlabeled_users_prediction...
iteration_2_unlabeled_users_prediction...
iteration_3_manual_labels_locals_vs_di...
iteration_3_manual_labels_person_vs_o...
iteration_3_manual_labels_target_pop...
iteration_3_unlabeled_users_prediction...
iteration_3_unlabeled_users_prediction...
iteration_3_unlabeled_users_prediction...
iteration_4_manual_labels_person_vs_o...
iteration_4_manual_labels_target_pop...
iteration_4_target_population_ambigu...
iteration_4_target_population_high_co...
iteration_4_unlabeled_users_prediction...
iteration_4_unlabeled_users_prediction...
iteration_4_unlabeled_users_prediction...
iteration_4_unlabeled_users_prediction...
iteration_5_unlabeled_users_pred... U
iteration_5_unlabeled_users_prediction...
iteration_6_unlabeled_users_prediction...
labeled_data_iteration_4_person_vs_or...

```

סיכום מפורט: למידה אקטיבית לעמודת Target Population

בשלב 15 יישמנו תהליך למידה אקטיבית (Active Learning) עבור עמודת Target Population, שמטרתו לשפר את המודל בצורה איטרטיבית תוך מינימום תיוג ידני. התהליך עובד כך: בכל איטרציה מאמנים מודל על הדאטה המתויג הקיים, מריצים אותו על כל הדאטה הלא מתויג, מחשבים לכל משתמש רמת ביטחון ואי וודאות, ואז בוחרים את המשתמשים עם אי הוודאות הגבוהה ביותר (TOP 100) לתיוג ידני בסבב הבא. לאחר התיוג הידני מוסיפים את התוויות החדשות לדאטה המתויג, מאמנים מודל מחדש, וחוזרים על אותו תהליך. בצורה הזו אנחנו "משקיעים" את זמן התיוג הידני רק במקרים שהמודל מתקשה בהם, מה שמאיץ שיפור ביצועים לאורך איטרציות.

דוגמה להתפלגות אי וודאות של המודל ועומת וודאות לאחר איטרציה ראשונה:

description_en	Display_name_en	Predicted_class	Prob_0_T	Prob_1_T	Prob_2_T	Confidence_Level	Uncertainty_Level
Official English a	Ajman club - En	1	0.24	0.53	0.23	0.53	0.47
Official Account	Al Wahda FC - E	1	0.24	0.53	0.23	0.53	0.47
	fargol	0	0.52	0.23	0.25	0.52	0.48
Week-long cele	Agatha All Along	0	0.52	0.23	0.25	0.52	0.48
skin and atti	Aghata	0	0.52	0.23	0.25	0.52	0.48
Engineering Po	Amirreza Ghomc	0	0.52	0.23	0.25	0.52	0.48
y God bless n	Dennise	2	0.24	0.24	0.52	0.52	0.48
edom by the	ali mir	2	0.24	0.24	0.52	0.52	0.48
ي الهلال السعو	ي الهلال السعودي	1	0.24	0.5	0.27	0.5	0.5
first 24/7 ho	Afghanistan Inte	1	0.25	0.49	0.25	0.49	0.51

בחירת מודל בכל איטרציה ולמה

נקודת ההתחלה (סוף Stage 14 תחילת Stage 15, Iteration 1)

לפני שהתחלנו למידה אקטיבית בפועל, בשלב 14 בנינו מסגרת ניסויים מלאה: בדקנו מספר אלגוריתמים, מספר סטים של פיצ'רים ושתי אסטרטגיות ולידציה LOOCV ו KFold וגם וריאציות של בעיה בינארית מול רב מחלקתית ואיזון מחלקות. מתוך ההשוואות האלו בחרנו את המודל שהציג את הביצועים הטובים/היציבים ביותר על הדאטה המתויג הקיים, והוא שימש כמודל ההתחלתי שמייצר את רשימת המועמדים לתיוג ידני באיטרציה הבאה.

במימוש הראשוני של Stage 15, עבור עמודת Target Population הוגדר מודל לוגיסטי רב מחלקתי עם שלוש מחלקות (target / non_target / unknown) עם מאפייני טקסט מסוג TF-IDF על תיאור הפרופיל ושם המשתמש. (TFIDF_description + username) הסיבה לכך היא שההחלטה אם משתמש שייך לאוכלוסיית היעד נשענת בעיקר על טקסט חופשי (תיאור/שם) ולכן TF-IDF מתאים כבסיס, ולוגיסטיק רגרסיה נותנת הסתברויות נוחות לחישוב ביטחון ואי וודאות.

לאחר תיוג ידני ראשון (Iteration 2 - אימון מחדש חזק יותר)

לאחר שיצרנו קובץ TOP 100 לאיטרציה 2, בוצע תיוג ידני, וקיבלנו קובץ תוויות חדש. באיטרציה הזו המטרה הייתה להרחיב את הדאטה המתויג ולשפר את מודל Target Population בצורה ממוקדת. לכן חיברנו (merge) את הדאטה המתויג מאיטרציה 1 עם התוויות החדשות של איטרציה 2, תוך ניהול כפילויות לפי username כך שתוויות מאוחרות יותר תדרוס תוויות ישנה במקרה הצורך. לאחר מכן אימנו מחדש מודל לוגיסטי רב מחלקתי.

שינוי חשוב באיטרציה 2 הוא הוספת מאפיינים מהונדסים במקום "חוקים קשיחים": במקום לקבוע כלל כמו "אם יש פרסית אז זה בהכרח איראני", הוספנו פיצ'רים שמאפשרים למודל ללמוד את

הדפוסים בעצמו. לדוגמה נוצרו מאפייני כתב (האם מופיע כתב ערבי/פרסי בטקסט) ומאפיין "פרופיל דל" (מעט עוקבים ומעט סטטוסים) כסיגנלים חלשים. הסיבה לשינוי הזה היא שהמידע הלשוני והמבני יכול להיות אינדיקציה, אבל הוא לא מספיק כדי להכריע לבד; כשהוא מוגדר כפיצ'ר, המודל יכול לשקלל אותו יחד עם הטקסט ולקבל החלטה סטטיסטית במקום החלטה כללית שעלולה להכניס הטיות.

באיטרציה הזו עדיין נשארנו במודל 3 מחלקות, אבל הוחלט לא להשתמש בדוגמאות "unknown" מהתיוג החדש כמידע לאימון, כדי לא "לבלבל" את המודל במקרים שהוגדרו מראש כלא חד משמעיים.

דוגמה למקבץ של רשומות לתיוג ידני לאיטרציה 3 עם רמות אי ביטחון גבוה :

Username	Display_name	Manual_target_population	Predicted_class	Uncertainty	Confidence	Description
abbasalawadi6	ABBAS Alawadi	0	0	0.5	0.5	نلي آبي طالب
algroonahmed	أحمد القرون	0	0	0.5	0.5	الأرض من يكسرك
ahmedovzaur78	Zaur Ahmadov	0	1	0.5	0.5	businessman
20rapcom	20RAP.com	1	1	0.5	0.5	رسي، تاسيس ۱۳۸۸
akram1445449	Akram	0	1	0.5	0.5	
abdelkarimslp	Abdelkarim	0	1	0.5	0.5	
afintlbrk	انستانت اينترنشنال	0	1	0.5	0.5	The First 24/7 In
77o7h	حسين	0	0	0.5	0.5	
aliyu_hass50470	Aliyu Adam Hass	2	0	0.5	0.5	
aleahmikul2052	Princess Queen	0	0	0.5	0.5	
4freedominiran	Iran Freedom	1	1	0.5	0.5	Representing act
ali_noorani_teh	Ali Noorani	1	1	0.49	0.51	Product designe
alokobra164379	alokobra	2	1	0.49	0.51	
akbarkhan025	Akbar kakar	0	0	0.49	0.51	pashtoonkhwa S
altynay1989	Алтынай Аскар	0	0	0.49	0.51	I am very simple
ainohuilaja	Aino Huilaja	0	1	0.49	0.51	Lapin noita maai
adeliatorp64676	Adelia Torphy	0	1	0.49	0.51	
alainfcae	نادي العين	0	1	0.49	0.51	في العين لكرة القدم

לאחר תיוג ידני שני (Post Iteration 3 - מעבר למודל בינארי)

לאחר שהתווספו עוד תוויות ידניות, בוצע שינוי מתודולוגי: עברנו לאימון מודל בינארי (0 מול 1) והוצאנו לחלוטין את "unknown=2" מהאימון. הסיבה למעבר היא שבפועל המטרה בשלב הזה היא לייצר סיווג חד לשתי מחלקות עבור רוב המשתמשים, ואת מקרי הגבול לטפל בהם באמצעות אי וודאות ובחירה לתיוג ידני, ולא להפוך אותם למחלקה "לימודית" בפני עצמה. ברגע שמכניסים unknown כחלק מהאימון, המודל עלול ללמוד "לברוח" למחלקה הזו או להתפזר על גבולות לא יציבים – במיוחד כשכמות unknown קטנה או לא עקבית.

באותה נקודה גם תיקנו בעיה שהתגלתה בזיהוי כתב: קודם היה ערבוב בין "כתב ערבי כללי" לבין "פרסית", ולכן פיצלנו את זה למאפיינים מדויקים יותר: האם יש כתב ערבי/פרסי כללי, האם מופיעות אותיות פרסיות ייחודיות (כמו پ چ ژ گ), והאם מופיעות וריאציות נפוצות של אותיות (למשל ك/ك, ي/ی). כלומר לא "ניחוש מדינה", אלא פיצ'רים לשוניים שמעלים את איכות הייצוג. בנוסף הוספנו מאפיינים משלימים כמו "האם הוזן מיקום בפרופיל" ו- log_followers כדי לייצב את השפעת המטריות הנומריות. האלגוריתם נשאר Logistic Regression בגלל שהוא יציב, מהיר, ונותן הסתברויות שמתאימות לחישוב uncertainty.

בשלב הזה עדיין החזרנו לקובץ תחזיות גם אינדיקציה אופציונלית של "unknown" לצורך סקירה ידנית באמצעות חלון הסתברויות סביב 0.5 (לדוגמה 0.3–0.7), אבל זה לא היה חלק מאימון המודל אלא רק עזר תפעולי לתעדוף בדיקה.

לאחר תיוג ידני שלישי (4 Post Iteration אותו מודל, יותר דאטה)


באיטרציה 4 המודל נשאר בינארי Logistic Regression עם אותו סט פיצ'רים (TF-IDF על טקסט מאוחד + פיצ'רי כתב + log_followers + location) אבל הוזן אליו דאטה מתווג גדול יותר מאיטרציות 1–4 יחד. כאן השיפור מגיע פחות משינוי אלגוריתם ויותר מהגדלת הדאטה המתווג בדיוק באזורים הקשים) כי בכל פעם בחרנו TOP 100 לא בטוחים. (התוצאה היא מודל מעודכן שמייצר שוב תחזיות על כל המועמדים ומוציא TOP 100 חדש לאיטרציה 5.

איך מחשבים אי וודאות ומה יוצא בכל ריצה

לאחר אימון, המודל רץ על כל המשתמשים הלא מתווגים ומחזיר הסתברות לכל מחלקה. אנחנו מחשבים confidence level כהסתברות הגבוהה ביותר, ואת uncertainty score בתור 1 פחות אותה הסתברות. כלומר ככל שהמודל "מתלבט" יותר (ההסתברויות קרובות), כך uncertainty score גבוה יותר. לאחר מכן ממיינים את כל המשתמשים לפי uncertainty score וחותכים את 100 הראשונים לתיוג ידני, כדי שהאיטרציה הבאה תוסיף מידע בדיוק באזורים שבהם המודל חלש.


ויזואליזציה של התהליך :

גרף זה משקף את יציבות המודלים בכל איטרציה. ירידה בסטיית התקן מצביעה על כך שהמודלים נהיים עקביים יותר ופחות רגישים לחלוקה אקראית של הדאטה.



התפלגות Confidence באיטרציה 1:


בהתחלה ההתפלגות רחבה יחסית ומראה הרבה חיזויים בעלי ביטחון בינוני, כלומר חוסר ודאות גבוה יחסית. מצב זה מצדיק שימוש בלמידה אקטיבית לבחירת דוגמאות מאתגרות לתיוג.



התפלגות


Confidence באיטרציה 4

ניתן לראות מעבר של המסה לכיוון ביטחון גבוה יותר, כלומר המודל נעשה בטוח יותר בחיזוייו. זהו סימן לכך שהלמידה האקטיבית הצליחה לצמצם את אזור אי הוודאות במרחב הנתונים.



Mean Accuracy & AUC – לאורך האיטרציות

הגרף מציג את השיפור הממוצע בביצועי המודלים לאורך איטרציות הלמידה האקטיבית. ניתן לראות מגמת התייצבות ואף שיפור הדרגתי, המעיד כי הוספת דוגמאות מתויגות מה- TOP 100 הבלתי בטוחים תרמה לאיכות המודל.



Person vs Organization (Active Learning)

במשימה זו סיווגנו משתמשי X/Twitter לשתי מחלקות עיקריות: **אדם (1)** מול **ארגון (0)**, כאשר בחלק מהאיטרציות נשמרה גם מחלקת **(2) unknown** לצורך דגימה/ניקוי אך הוצאה מהאימון הבינארי. המטרה הייתה לבנות מסווג אמין שמייצר גם **הסתברות** וגם **מדד אי ודאות**, כדי להפעיל תהליך Active Learning שממקד תיוג ידני דווקא בדוגמאות הקשות.

2. הלולאה הכללית של Active Learning - איך זה עובד אצלנו בפועל

בכל איטרציה ביצענו: (1) איסוף תיוגים ידניים חדשים, (2) מיזוגם לסט המתויג המאוחד תוך טיפול בכפילויות לפי (3) username, אימון מודל עם פיצ'רים טקסטואליים + (TF-IDF) פיצ'רים מספריים/חוקיים, (4) חיזוי על מאגר לא-מתויג, (5) חישוב confidence/uncertainty ו-(6) בחירת מועמדים לתיוג ידני (Top-uncertain או דגימה לפי band). בצורה הזו איכות המודל משתפרת עם מינימום תיוג מבזבז.

(3) Iteration 2 - מודל האימון ראשון אחרי תיוג ידני (Stage 15 continuation)

באיטרציה 2 שילבנו תיוגים ידניים חדשים עם הדאטה המתויג מאיטרציה 1, ניקינו דוגמאות חסרות תווית והסרנו "unknown" מהאימון הבינארי. המודל אומן כ- Logistic Regression על TF-IDF משולב (username+display_name+description) יחד עם פיצ'רים מהונדסים שמחזקים הבחנה בין אדם לארגון (מילות מפתח של תפקידים/ארגונים, שפה ברבים, "we/our" ומדדי פרופיל כמו followers/following/statuses). בסוף ייצרנו קובץ חיזוי לכל הלא-מתויגים + קובץ **Top-100 הכי לא בטוחים** לתיוג ידני לאיטרציה הבאה.

(4) Iteration 3-4 - הרחבת הדאטה ושיפור איכות ע"י תרגום + חיפוש מודל/פיצ'רים (Grid)

באיטרציות 3-4 המשכנו להגדיל את סט התיוג דרך קבצי manual נוספים, ובמקביל טיפלנו בבעיית שפה ע"י שימוש בעמודות מתורגמות לאנגלית (description_en, display_name_en) כדי לשפר עקביות TF-IDF בנוסף הרצנו **Grid Experiments** (Stage 17) על קומבינציות שונות של פיצ'רים: TF-IDF על description/username/full_name וכן הוספת בלוק מספרי (followers/following/statuses/verified) ודגלי מילות מפתח. (PERSON_KEYWORDS/ORG_KEYWORDS) מטרת הגריד הייתה לקבל תמונת מצב אמפירית של מה עובד טוב יותר תחת CV (KFold/LOOCV) ולבחור משפחת מודלים חזקה.

אחרי 2 Iteration: בחרנו **Logistic Regression** כבסיס כי הוא יציב על TF-IDF, נותן הסתברויות שימושיות למדידת אי ודאות, והוא מהיר לאימון החוזר בכל סבב Active Learning. בנוסף שילבנו פיצ'רי "רמזי ארגון/אדם" כדי לסגור פערים סמנטיים כשאין טקסט עשיר.

אחרי 4 Iteration: ביצענו **Grid** והתחלנו לבחור תצורות לפי ביצועי (accuracy/AUC) CV על סט מתווג גדול יותר. כאן כבר בדקנו גם מודלים נוספים למשל (SVM / RandomForest / XGBoost) וגם וריאציות Feature Sets כדי לוודא שהשיפור מגיע מהדאטה ומהפיצ'רים ולא רק ממזל של חלוקה.

אחרי 5-6 Iteration: למרות שמודלים מסוימים יכולים לנצח נקודתית בגריד, בחרנו קונפיגורציה של **Logistic Regression** עם Feature Set (description+username+full_name+NUM) עשיר כדי לשמור על **הסתברויות נקיות לאי-ודאות**, יכולת הסבר גבוהה, ויציבות אימון חוזר כשהדאטה גדל.

6 Iteration - דגימה לפי Confidence Bands

באיטרציה 5 לא הסתפקנו רק ב Top-uncertain, אלא הוספנו מנגנון **דגימה לפי רצועות ביטחון (confidence bands)**: דגמנו למשל 20 משתמשים מכל טווח confidence כדי לקבל גם דוגמאות קלות לחיזוי וגם בינוניות, ולהקטין הטיה של סט מתווג שמכיל בעיקר מקרי קצה. אחרי תיוג הדוגמאות המייצגות האלה, מיזגנו אותן לקובץ המתווגים והשתמשנו בהן כדי לייצב את המודל ולשפר כיסוי של דפוסים נפוצים.


7 Iteration - מיזוג תיוגים חדשים, תרגום תקין, אימון

באיטרציה 6 ביצענו מיזוג מסודר של כל התיוגים כולל confidence-bands לקובץ מתווג מאוחד, ודאגנו שעמודות התרגום באמת קיימות ומלאות לפני אימון. לאחר מכן הרצנו קונפיגורציה מוגדרת מראש **Logistic Regression + LOOCV + TF-IDF(description+username+full_name)** ולאחר הערכת LOOCV אימנו על כל המתווג וחזינו את כל הדאטה הלא-מתווגת. לבסוף הפקנו דוחות דיאגנוסטיקה: השוואת התפלגות תיוגים באימון מול התפלגות חיזויים, וטבלת thresholds שמראה איך שינוי סף confidence משפיע על כמות הדאטה שנשארת ועל יחס המחלקות.



טבלת החיזוי על הדאטה הלא מתווג אחרי איטרציה 6 ואחרונה:

file_banner	Description_en	Display_name_en	Predicted_class	Confidence_level	Prob_0	Prob_1	Uncertainty_score	Prob_2
	Spouse - Journal	Ali Kalaei	1	0.87	0.13	0.87	0.13	
	Likes and retwee	amin ajami	1	0.87	0.13	0.87	0.13	
		Alastair Murray	1	0.88	0.12	0.88	0.12	
	konu vatansa ge	Ali Fuat Cebeci	1	0.88	0.12	0.88	0.12	
	The Astrid Lindg	Astrid Lindgren I	0	0.89	0.89	0.11	0.11	
		Adelia Torphy	1	0.89	0.11	0.89	0.11	
		ModestyYale	1	0.89	0.11	0.89	0.11	
	vocalista do two	ketaminion	1	0.9	0.1	0.9	0.1	
	digital editor @	Josh Kaplan	1	0.9	0.1	0.9	0.1	
	Students followi	Abdul Majeed Ki	1	0.9	0.1	0.9	0.1	
	AIR Center is a t	AIR Center	0	0.91	0.91	0.09	0.09	
	PahlaviReza@#K	👑 Adel-irani012	1	0.91	0.09	0.91	0.09	
	Broker and dire	Song Flight Airlin	1	0.91	0.09	0.91	0.09	
	Ummat-orientec	Abu Muhammac	1	0.93	0.07	0.93	0.07	
		A@dil Şultan	1	0.93	0.07	0.93	0.07	
	Student of Ahlul	Ahlul-Bayt 🇮🇷	1	0.94	0.06	0.94	0.06	
		ali hshemi	1	0.95	0.05	0.95	0.05	
	The Official Engl	Al Ahly SC gb	0	0.96	0.96	0.04	0.04	
	American Media	Adelle Nazarian	1	0.96	0.04	0.96	0.04	
		Ahmed Saleh	1	0.96	0.04	0.96	0.04	
	teaching physics	aghajani76m	1	0.96	0.04	0.96	0.04	
		Alex Curran	1	0.97	0.03	0.97	0.03	
		あああ	1	0.97	0.03	0.97	0.03	
		alex	1	0.98	0.02	0.98	0.02	

בגרף זה ניתן לראות את השיפור בביטחון של המודל ככל שהדאטה גדל אחרי כל איטרציה, וירידה ברמות החוסר ביטחון :





בגרפים אלה מוצג העלייה בממוצעים של הדיוק ומדדי AUC-ROC של כל הניסויים הבינאריים במהלך כל התהליך.




דיוק לפי איטרציה ומודל חיזוי שנבחר.

ממוצעי דיוק לפי אלגוריתם חיזוי:



גרף שמראה שרמות הדיוק, ביטחון ו-AUC עולות ככל שהדאטה גדל המודל נהיה טוב יותר.



בחירת אלגוריתם לאורך האיטרציות – נימוק מתודולוגי

באיטרציה הראשונה נבחר מודל **Logistic Regression** כמודל בסיסי (Baseline) משום שמדובר בבעיה טקסטואלית עם ייצוג TF-IDF דליל, ולוגיסטיק רגרשן ידוע כיעיל, יציב ומהיר בלמידה על נתונים מסוג זה. בנוסף, הוא מספק הסתברויות ברורות המאפשרות חישוב רמות ביטחון ו-uncertainty רכיב קריטי בתהליך למידה אקטיבית.

באיטרציה השנייה, לאחר הרחבת הדאטה המותגי, בוצעה השוואה בין מספר אלגוריתמים Logistic Regression, Decision Tree, Random Forest, SVM, XGBoost למרות שחלק מהמודלים המורכבים השיגו לעיתים Accuracy דומה, Logistic Regression הציג יציבות גבוהה יותר בין KFold ל-LOOCV ופער קטן יותר בין train ל-validation ולכן נבחר שוב כמועמד המוביל.

באיטרציה השלישית והרביעית, כאשר נוספו פיצ'רים מהונדסים כגון numeric | keyword flags features, מודלים מבוססי עצים כמו XGBoost | Random Forest החלו להראות שיפור ביכולת ללכוד אינטראקציות לא לינאריות. עם זאת, לאחר ניתוח AUC ו-F1, נמצא כי Logistic Regression עדיין מספק איזון טוב יותר בין דיוק, הכללה ויציבות סטטיסטית – במיוחד כאשר balanced=False.

באיטרציה החמישית, לאחר הרחבה משמעותית של סטי הפיצ'רים: שילוב username description + full_name + NUM+ בוצעה בחירה מחודשת על בסיס Top-20 תוצאות מ-experiments_results.csv למרות שמודלים מורכבים הגיעו לשיאים נקודתיים גבוהים יותר, Logistic Regression נבחר משום שהציג ביצועים עקביים ב-LOOCV, ללא רגישות גבוהה לשינויים בגודל המדגם – תכונה חשובה כאשר הדאטה המותגי עדיין מוגבל.

באיטרציה השישית, לאחר הוספת דוגמאות מאזורי ביטחון שונים (confidence bands) והגדלת הדאטה המותגי, נבדקה מחדש תצורת Logistic Regression עם סט הפיצ'רים הרחב ביותר. הבחירה נשמרה, משום שהמודל הציג שיפור ב ROC-AUC וב mean confidence תוך שמירה על פרשנות גבוהה של המשקלים, דבר שמאפשר להבין אילו מאפיינים תורמים להחלטה בין Person ל-Organization.

בסיכום, לאורך כל האיטרציות הבחירה ב-Logistic Regression לא נבעה מפשטות בלבד, אלא משילוב של:

יציבות בין ולידציות שונות,
יכולת עבודה מיטבית עם TF-IDF דליל,
שקיפות ויכולת הפקת ציוני ביטחון אמינים לצורך למידה אקטיבית.

Local VS Diaspora (Active Learning)

מטרת המשימה הייתה לסווג משתמשים איראנים לשתי קבוצות מקומיים החיים באיראן, ודיאספורה החיים מחוץ לאיראן

הסיווג בוצע רק על משתמשים שכבר זוהו כאיראנים במשימת target population. כלומר זו משימת סיווג שנייה המבוצעת על תת קבוצה מסוננת מראש.

יצירת מאגר בסיס

בשלב הראשון נבנה מאגר בסיס לכל המשתמשים האיראנים. המאגר כלל שני מקורות עיקריים

משתמשים שסומנו ידנית כאיראנים בכל איטרציות התיג של target population
משתמשים שחזו כאיראנים על ידי המודל האחרון של target population

לאחר איחוד הנתונים בוצעה הסרת כפילויות לפי שם משתמש. נשמרה עדיפות לשורות שמקורן בתיג ידני.

מאגר זה שימש כנקודת פתיחה ללמידה האקטיבית של לוקל מול דיאספורה.

דגימה ראשונית לתיוג ידני

כדי להתחיל את הלמידה נבחר מדגם ראשוני של ארבעים משתמשים.

עשרים משתמשים עם שדה מיקום מלא
ועשרים משתמשים ללא שדה מיקום

הכוונה הייתה לכלול גם מקרים שקל יחסית להכריע בהם לפי מיקום וגם מקרים שדורשים ניתוח מעמיק של תיאור המשתמש והשם.

תיוג זה יצר את סט האימון הראשון של המשימה.

תהליך הלמידה האקטיבית

המשימה בוצעה במספר איטרציות עוקבות.
בכל איטרציה בוצעו השלבים הבאים

אימון מספר מודלים שונים על הדאטה המתיוג הקיים
בדיקת ביצועים באמצעות ולידציה
בחירת מודל מוביל לפי דיוק ויכולת הפרדה
הרצת המודל על כל המשתמשים הלא מתיוגים
חישוב רמת ביטחון לכל תחזית

בחירת המשתמשים בעלי אי ודאות גבוהה לצורך תיוג ידני נוסף

לאחר כל איטרציה התיוגים החדשים אוחדו לסט האימון והתהליך חזר על עצמו.

כך גדל בהדרגה מאגר הדוגמאות המתיוגות והמודל השתפר.

הנדסת תכונות

בשלבים הראשונים נעשה שימוש בעיקר בתכונות טקסטואליות

וקטורי TFIDF על תיאור המשתמש
וקטורי TFIDF על שם המשתמש
וקטורי TFIDF על שם התצוגה

בהמשך נוספו תכונות נוספות שחיזקו את ההבחנה בין מקומיים לדיאספורה

זיהוי האם שדה המיקום מכיל אזכור של איראן או ערים מרכזיות באיראן
זיהוי האם התיאור או השם מכילים תווים בפרסית

תכונות אלו תרמו מידע חזק במיוחד במקרים שבהם הטקסט היה קצר או לא חד משמעי.

תוצאות לאורך האיטרציות

בניתוח מגמת הביצועים לאורך האיטרציות נצפתה קפיצה משמעותית בתחילת התהליך.
לאחר מכן חל שיפור מתון יותר ובהמשך התייצבות במדדי הדיוק.

באיטרציות המאוחרות לא נרשם שיפור מהותי נוסף.

ממצא זה מעיד כי המודל מתקרב לרוויה מבחינת תרומת דוגמאות תיוג נוספות.

לצורך בחינת תנאי עצירה בוצע גם ניתוח רמות הביטחון של המודל על המשתמשים הלא מתיוגים.

ממוצע רמת הביטחון עמד על כ 0.73
טווח הביטחון נע בין כ 0.5 לבין כ 0.95

נמצא כי מספר המשתמשים באזור אי ודאות קיצוני היה נמוך יחסית.
עם זאת עדיין קיים פיזור רחב של רמות ביטחון.

מסקנה

תהליך הלמידה האקטיבית עבור לוקל מול דיאספורה הביא לשיפור משמעותי בשלביו הראשונים ולאחר מכן להתייצבות.




ניתוח הביצועים יחד עם בחינת רמות הביטחון מצביעים על כך שהמודל הגיע לרוויה יחסית. תוספת תיוגים נוספים צפויה להניב שיפור קטן בלבד.

לכן ניתן לקבוע כי בשלב זה מתקיים תנאי עצירה סביר לתהליך.

Iteration	Training_type	Algorithm	Feature_set	Balanced	#classes	N_samples	Min_class_size	Accuracy	Precision	Recall	F1	AUC
1	KFold	DecisionTree	TFIDF_full_name	False	2	19	8	0.74	0.69	1	0.81	0.69
2	LOOCV	AdaBoost	TFIDF_descriptio	False	2	40	13	0.8	0.8	0.8	0.8	0.76
3	KFold	SVM	TFIDF_descriptio	False	2	120	32	0.77	0.75	0.77	0.72	0.69
4	LOOCV	SVM	TFIDF_descriptio	False	2	160	45	0.76	0.75	0.76	0.72	0.65
5	LOOCV	AdaBoost	TFIDF_all_text+lc	False	2	210	68	0.73	0.71	0.73	0.71	0.72
*												

טבלה המציגה את המודל שנבחר בכל איטרציה של חיזוי עם כל הפרטים.

גרפים לסיכום מדדי AUC ו-Accuracy לאורך התהליך




הגרף מציג את התקדמות תהליך הלמידה האקטיבית במשימת לוקל מול דיאספורה לאורך האיטרציות. ניתן לראות כי בשלב הראשון הדיוק והיכולת להפריד בין הקבוצות היו ברמה בינונית, ולאחר הוספת דוגמאות מתיוגות באיטרציות הבאות חל שיפור הדרגתי בביצועים. הדיוק וה AUC עולים בצורה עקבית עד לאיטרציות המאוחרות, מה שמעיד על למידה אפקטיבית מהדאטה החדש שנוסף בכל שלב. במקביל ניתן לראות כי גודל הדאטה המתווג גדל בצורה רציפה, דבר שתומך בהשתפרות המודל. רמת הביטחון הממוצעת של התחזיות עולה גם היא בהדרגה, מה שמצביע על כך שהמודל נעשה יציב יותר בהחלטותיו. עם זאת, באיטרציות האחרונות קצב השיפור במדדים מתמתן, דבר המרמז על התקרבות לרוויה ולשלב שבו תרומת תיוג נוסף קטנה יחסית.

שלב 16 תנאי עצירה

עמודה 1 זיהוי איראנים


במשימה זו נצפתה קפיצה משמעותית בדיוק באיטרציות הראשונות ולאחר מכן התייצבות במדדים. תוספת דוגמאות תיגו נוספות לא הובילה לשיפור מהותי נוסף. בנוסף רמת הביטחון של המודל על הדאטה הלא מתויג הייתה גבוהה ויציבה. לכן ניתן לקבוע כי המודל הגיע לרוויה וכי תנאי העצירה התממש.



Iteration ▾	N_experiments	Mean_accuracy	Mean_AUC ▾	Std_accuracy	Max_accuracy
1	168	0.53	0.41	0.14	1
2	120	0.51	0.46	0.09	0.72
3	336	0.59	0.57	0.08	1
4	476	0.8	0.8	0.03	0.87

עמודה 2 אדם מול ארגון

גם במשימה זו נראה שיפור ברור בתחילת תהליך הלמידה האקטיבית ולאחר מספר איטרציות הביצועים התייצבו. הפער בין איטרציה לאיטרציה נעשה קטן מאוד. במקביל רמת הביטחון של התחזיות עלתה והפיזור של אי ודאות קיצונית היה נמוך יחסית. מצב זה מצביע על כך שהמודל למד את הדפוסים המרכזיים ולכן תנאי העצירה התקיים.




Iteration ▾	N_experiments	Mean_accuracy	Max_accuracy	Mean_AUC ▾	Mean_class_0	Mean_class_1	Min_class_size
1	168	0.63	0.82	0.47	22	43.5	22
2	120	0.61	0.77	0.51	22	43.5	22
3	336	0.67	1	0.59	88	139.5	88
4	336	0.65	0.75	0.58	124	183.5	124
5	90	0.74	0.79	0.66	149	317	149
6	80	0.76	0.8	0.68	155	372	155

עמודה 3 לוקל מול דיאספורה

במשימת לוקל מול דיאספורה נצפתה עלייה הדרגתית בדיוק וב AUC לאורך האיטרציות הראשונות, ולאחר מכן התמתנות בקצב השיפור. רמת הביטחון הממוצעת עלתה אך לא באופן קיצוני, והמודל הציג יציבות בהחלטותיו. תוספת תיוגים נוספת צפויה להביא לשיפור קטן בלבד. לכן ניתן לקבוע כי המודל הגיע לרוויה יחסית ותנאי העצירה מתקיים גם בעמודה זו.

Iteration ▾	N_experiments	Mean_accuracy	Std_accuracy	Best_accuracy	Mean_auc ▾	Best_auc ▾	Median_sample	Max_samples
1	336	0.4	0.19	0.74	0.36	0.77	21.5	33
2	264	0.59	0.12	0.8	0.49	0.76	33	40
3	120	0.63	0.11	0.77	0.56	0.74	92	120
4	120	0.63	0.08	0.76	0.55	0.68	125	160
5	252	0.62	0.06	0.73	0.58	0.75	173	210



שלב 17 בחירת סף ביטחון ואימות איכות אוכלוסיית היעד

בשלב זה הופעל המודל הסופי שנבחר בכל אחת מהמשימות על כלל הדאטה, הן המתויג והן הלא מתויג. לכל משתמש חושבה רמת ביטחון, המוגדרת כהסתברות הגבוהה ביותר מבין המחלקות שחזה המודל.

המטרה בשלב זה הייתה להגדיר סף ביטחון תפעולי אשר יאפשר הכללת משתמשים באוכלוסיית היעד תוך שמירה על רמת דיוק גבוהה. לצורך כך בוצעה בחינה שיטתית של התפלגות רמות הביטחון.

עמודה 1 זיהוי איראנים

לאחר ניתוח התפלגות רמות הביטחון נבחנו שלושה ספים עיקריים: 0.9, 0.8 ו 0.7.

ברמת ביטחון של 0.9 התקבלה אמינות גבוהה מאוד אך כיסוי מצומצם יחסית של משתמשים. ברמת ביטחון של 0.7 התקבל כיסוי רחב מאוד אך נצפתה ירידה מסוימת באיכות.

לפיכך נבחר סף ביטחון של 0.8 אשר מהווה איזון בין כיסוי מספק לבין רמת אמינות גבוהה.

לצורך אימות בוצעה בדיקה ידנית אקראית של 100 משתמשים מתוך אלו שסווגו מעל סף 0.8. נמצא כי 93 מהם אכן שייכים לאוכלוסיית היעד. לפיכך שיעור הפגיעה עמד על 93 אחוז.

בהתאם לכך נקבע כי סף 0.8 מספק רמת דיוק תפעולית גבוהה תוך שמירה על היקף אוכלוסייה משמעותי.

עמודה 2 אדם מול ארגון

במשימה זו נותחה התפלגות הביטחון ונמצא כי כמות המשתמשים מעל 0.9 הייתה נמוכה יחסית, בעוד שמעל 0.7 התקבל כיסוי רחב אך עם שונות גבוהה יותר.

נבחר סף ביטחון של 0.75 אשר שימש כנקודת איזון בין סף 0.7 הרחב לבין סף 0.8 המצמצם.

בוצעה בדיקת ולידציה ידנית על מדגם של 80 משתמשים שסווגו מעל הסף. בבדיקה נמצא כי 71 מהם סווגו נכון. שיעור הפגיעה עמד על 88.7 אחוז.

תוצאה זו אישרה כי רמת הביטחון של המודל משקפת אמינות גבוהה, ולכן סף זה שימש להגדרת אוכלוסיית היעד הסופית.

עמודה 3 לוקל מול דיאספורה


במשימת לוקל מול דיאספורה נותחה התפלגות רמות הביטחון על כלל 156 המשתמשים.

נמצא כי ברמת ביטחון של 0.9 הכיסוי היה נמוך יחסית, בעוד שברמת 0.7 התקבל כיסוי רחב אך עם שונות גדולה יותר בין תחזיות יציבות לפחות יציבות.

לפיכך נבחר סף ביטחון של 0.8, אשר מספק איזון מיטבי בין איכות לבין היקף.

בוצעה בדיקת איכות ידנית על 60 משתמשים שנבחרו אקראית מתוך אלו שסווגו מעל 0.8. נמצא כי 52 מהם אכן סווגו נכון. שיעור הפגיעה עמד על 86.7 אחוז.

תוצאה זו מצביעה על כך שהמודל מספק רמת אמינות מספקת לשימוש תפעולי ברמת סף זו.



בגרף מוצגת התפלגות רמות הביטחון בשלוש המשימות. העמודות הכחולות מייצגות משתמשים שסווגו ברמת ביטחון של 0.9 ומעלה. העמודות הכתומות מייצגות רמת ביטחון של 0.8 ומעלה. העמודות הירוקות מייצגות רמת ביטחון של 0.7 ומעלה.

ניתן לראות כי במשימת זיהוי איראנים קיימת כמות גדולה משמעותית של משתמשים המסווגים בביטחון גבוה. במשימת אדם מול ארגון ובמשימת לוקל מול דיאספורה מספר המשתמשים בביטחון גבוה קטן יותר, אך עדיין קיימת קבוצה ברורה של תחזיות יציבות שניתן להסתמך עליהן לצורך הגדרת אוכלוסיית היעד.

סיכום

בכל שלוש המשימות נבחר סף ביטחון שאינו הגבוה ביותר האפשרי, אלא כזה שמאזן בין אמינות לבין כיסוי.

בכל המקרים בוצעה בדיקת ולידציה ידנית מדגמית, ושיעור הפגיעה שהתקבל אישר כי רמת הביטחון המודלית מהווה אינדיקציה אמינה לאיכות הסיווג.

שלב 18 – איסוף ציוצים עבור אוכלוסיית היעד המסווגת (Post-Confidence Filtering)

לאחר השלמת שלב 17, שבו יושם תהליך Active Learning לצורך סיווג משתמשים והבחנה בין **Person** לבין **Organization** וכן סיווג ל- **Target Population**, בוצע שלב איסוף הציוצים אך ורק עבור משתמשים שעמדו בקריטריונים המחמירים שהוגדרו מראש.

קריטריוני סף לאיסוף ציוצים

האיסוף בשלב זה לא בוצע על כלל המשתמשים, אלא רק על תת אוכלוסייה שעברה סינון כפול:

1. **Account Type = Person בלבד**
משתמשים שסווגו כארגונים (Organizations) הוחרגו לחלוטין מהשלב, בהתאם להנחיות הפרויקט המגדירות שהניתוח הטקסטואלי מתמקד בהתנהגות משתמשים פרטיים.
2. **Target Population = Target בלבד**
נאספו ציוצים אך ורק מחשבונות שהמודל סיווג כשייכים לאוכלוסיית המטרה, לאחר מספר איטרציות של שיפור מודל.
3. **Confidence Threshold גדול שווה מהסף שנקבע בשלב 17**
רק משתמשים שעבורם הסתברות הסיווג (Prediction Probability) הייתה מעל סף הביטחון שנקבע (Confidence Threshold) שנבחר אמפירית על בסיס trade-off בין Precision ל-Coverage הועברו לשלב איסוף הציוצים.

בחירה זו מבטיחה כי שלב 18 מבוסס על משתמשים בעלי רמת ודאות גבוהה בסיווגם, ומונעת "זליגת רעש" מאוכלוסיות לא רלוונטיות או מסיווגים לא בטוחים.

שילוב סף הביטחון לפני שלב האיסוף משרת מספר מטרות מחקריות:

- הגדלת **Precision** של אוכלוסיית הניתוח
 - הפחתת איסוף מיותר מחשבונות גבוליים
 - צמצום סיכון להכנסת ארגונים או משתמשים שאינם שייכים לאוכלוסיית היעד
 - חיסכון במשאבי זמן חישוב ואיסוף
- באופן זה, שלב 18 אינו שלב איסוף גנרי, אלא שלב המשך ישיר לתהליך הסיווג והוולידציה שבוצע בשלב 17.

יישום בפועל

לאחר יישום סינון ה- Confidence Threshold והחרגת ארגונים:

- הופקה רשימת משתמשים סופית לאיסוף
- משתמשים אלה הועברו למודול TwitterSeleniumCollector
- לכל משתמש נאספו ציוצים בטווח התאריכים שהוגדר
- נשמרו קבצי timeline נפרדים לכל משתמש

האיסוף כלל מנגנוני:

- Resume (למניעת כפילויות)
- Checkpointing
- בקרה על תקלות

- בקרה על טווח תאריכים

תוצאה

בסיום שלב זה התקבל מאגר ציורים המייצג:

- משתמשים פרטיים בלבד (Person)
- השייכים לאוכלוסיית המטרה (Target)
- עם רמת ודאות סיווג גבוהה ($\text{Confidence} \geq \text{threshold}$)

ובכך מובטח כי הדאטה הטקסטואלי שעליו מתבצעים שלבי הניתוח הבאים נשען על תהליך סינון שיטתי, מבוסס מודל, ובהלימה מלאה להנחיות הפרויקט.

איך איסוף הציורים התבצע בפועל (מבחינת הקוד)

1) הכנה וסינון משתמשים לאיסוף

הקוד טען קובץ בסיס של משתמשים, זיהה את עמודת שם המשתמש למשל (username), והפיק רשימת משתמשים ייחודית.

בנוסף בוצעה שכבת סינון כדי להתמקד באוכלוסייה הרלוונטית (לפי השדות והסינונים שהוגדרו בפרויקט), ולאחר מכן בוצעה החרגה של משתמשים שכבר נאספו בעבר באמצעות קובץ תוצאות/רשימת "כבר נאספו", כדי למנוע כפילויות ולחסוך זמן ריצה.

2) שימוש בדפדפן אוטומטי לאיסוף

האיסוף בוצע בעזרת דפדפן כרום אוטומטי שרץ בצורה "שקטה" (בלי חלון פתוח) כדי לאפשר ריצה ארוכה ויציבה.

כדי לשפר גישה לתוכן ולהקטין חסימות, הקוד טען עוגיות התחברות מקובץ ייעודי, רענן את הדף ואז התחיל עבודה על פרופילים.

3) איסוף ציורים מתוך דף הפרופיל

לכל משתמש:

- הקוד נכנס לדף הפרופיל שלו.
- בדק אם החשבון קיים / לא מושעה.
- איתר את "רכיבי הציורים" בדף (כל ציוץ מופיע כאלמנט בעמוד).
- מכל ציוץ חילץ שדות מרכזיים: מזהה ציוץ, תאריך, טקסט, וקישורים, ובנוסף מדדים כמו לייקים/שיתופים/תגובות כאשר הם היו זמינים.

4) גלילה מבוקרת עד שמפסיקים להגיע ציורים חדשים

מאחר והעמוד נטען בצורה דינמית (כלומר עוד ציורים נטענים רק כשגוללים), הקוד ביצע לולאת גלילה:

- בכל גלילה נאספו כל הציורים החדשים שנוספו למסך.
- נשמר סט של מזהי ציורים שכבר נאספו כדי למנוע כפילויות.
- אם בוצעו כמה גלילות ברצף בלי להגיע ציורים חדשים, התהליך נעצר אוטומטית כדי לא לבזבז זמן.

בנוסף הוגדרו פרמטרים ששולטים על כמות הגלילות ועל זמן ההמתנה בין גלילות, כדי ליצור איזון בין מהירות איסוף לבין מניעת חסימות.

5) סינון לפי טווח תאריכים

לאחר חילוץ תאריך הציוץ, הקוד בדק האם הוא נמצא בתוך טווח התאריכים שהוגדר מראש. ציוצים מחוץ לטווח לא נשמרו לקובץ, כך שהדאטה הסופי נשאר עקבי עם חלון הזמן שנבחר למחקר.

6) שמירת תוצרים לכל משתמש + קובצי סיכום

לכל משתמש נשמר קובץ נפרד עם כל הציוצים שנאספו עבורו. בנוסף נשמר קובץ תוצאות כולל שמציג עבור כל משתמש אם האיסוף הצליח, כמה ציוצים נאספו, ואם הייתה שגיאה אז מה הייתה הסיבה. בסיום נוצר גם קובץ סטטיסטיקות מסכם (כמה משתמשים נאספו, כמה נכשלו, וכמה ציוצים נאספו בסך הכול).

Tweet_id	Username	Created_at	Text
1961413769302	alishakourirad	2025-08-29 16:0	گره خورده است # ران رقم می خورد #
1706468313142	alishakourirad	2023-09-26 03:3	بد تصمیم گرفت ۱۳
1696961633711	alishakourirad	2023-08-30 22:0	به علم تولید کردیم تنکی را متحول کرد و آنها دنیا را گرفتند و بیدار شده باشیم
1682212386474	alishakourirad	2023-07-21 05:1	به انتخاب می زنند و دن انتخابات ندارد نه توصیه و تحذیر
1668525761911	alishakourirad	2023-06-13 10:4	بی در کشور است و به قانون برگردیم و اراده مردم است و رأی ملت است #

Username	Total_tweets	Tweets_2022	Tweets_2023	Tweets_2024	First_tweet	Last_tweet
0alwaysdreamer	131	0	0	0	2021-12-02 00:0	2026-02-14 00:2
0mfahzf4tebztld	9	1	3	1	2022-04-21 23:2	2026-02-09 19:1
0qcgdh3bdamfc	104	0	0	77	2024-03-20 17:2	2025-12-09 21:2
105_sakariyou	80	12	0	0	2021-11-14 20:1	2022-01-17 12:4
1364ghazal6281	1	0	1	0	2023-04-09 21:0	2023-04-09 21:0
13viriniawoolf	119	0	0	0	2025-11-23 14:2	2026-02-15 08:5

7) مانگنون המשך ריצה (Checkpoint) ואיסוף חוזר

כדי להתמודד עם ריצות ארוכות ותקלות, הקוד שמר קובץ שמכיל מי כבר נאסף ומי נכשל. בזכות זה ניתן היה לעצור ולהמשיך בלי להתחיל מחדש. במקרים שבהם זוהו משתמשים שלא נאספו או שנאספו עם 0 ציוצים, נוצר קובץ ייעודי של "לא נאספו" ורצו עליהם שוב עם הגדרות איטיות יותר (יותר זמן המתנה ופחות גלילות), מה שהעלה משמעותית את שיעור ההצלחה.


בסך הכול נאספו כ-21,000 ציוצים מחשבונות המשתמשים שעברו את שלב הסינון והעמידה בסף הביטחון. נפח נתונים זה מאפשר ניתוח טקסטואלי מובהק ומשמעותי, הן ברמת המשתמש הבודד והן ברמת מגמות רוחב לאורך זמן.

כמות זו מספקת בסיס נתונים מספק לניתוח תוכן, השוואות בין קבוצות, ובחינת דפוסים טמפורליים, תוך שמירה על עקביות עם קריטריוני הסינון והביטחון שהוגדרו בשלבים הקודמים.

ציוצים שנאספו לפי שנים :

Year	Tweet_count
2011	1
2012	27
2014	1
2015	8
2016	18
2017	164
2018	286
2019	212
2020	290
2021	600
2022	1172
2023	962
2024	1975
2025	7246
2026	8821

הגרף מציג את התפלגות מספר הציוצים למשתמש עבור 238 משתמשים, מהם נאספו בסך הכול 21,810 ציוצים. ניתן לראות שרוב המשתמשים מפרסמים עשרות עד מעט יותר ממאה ציוצים בטווח הזמן שנבדק, בעוד שקיימים מספר מצומצם של משתמשים פעילים במיוחד עם מאות ציוצים, היוצרים זנב ימני ארוך בהתפלגות.



שלב 20 – תרגום הפוסטים לאנגלית

בשלב זה תורגמו כלל הציוצים שנאספו לשפה האנגלית על מנת לאפשר ניתוח טקסטואלי אחיד ועקבי בהמשך הפרויקט. התרגום בוצע באופן אוטומטי באמצעות Google Translate API תוך עיבוד באצוות (Batch Processing) למניעת תקלות ושמירה על יציבות התהליך.

הטקסט המתורגם נשמר בעמודה חדשה בשם text_translated_en בקובץ המרכזי, אשר שימש בהמשך כקלט לשלבי ה־ Sentiment Analysis, Emotion Analysis ו־Topic Modeling.

Text_original	Text_en
#Thanks_to_Kuwait	#Thanks_to_Kuwait
Wishing victory to the Iraqi people	Wishing victory to the Iraqi people
...	...
#iranelection #iran	#iranelection #iran
Bismillah Rahman Rahman	Bismillah Rahman Rahman
Epstein scandals	Epstein scandals
Follow the Arab Spring	Follow the Arab Spring
1/3 Visit of His Eminence	1/3 Visit of His Eminence
A joint delegation	A joint delegation
Former US President	Former US President
Follow the Arab Spring	Follow the Arab Spring

שלב 21 – ניתוח סנטימנט (Sentiment Analysis) על ציוצים מתורגמים

בשלב זה בוצע ניתוח סנטימנט לציוצים לאחר תרגומם לאנגלית (שלב 20), במטרה לאפיין את הטון הכללי של השיח. תחילה בוצע ניקוי טקסט (הסרת קישורים, RT, אזכורים @, והמרת hashtags למילים רגילות), תוך שמירה על אמוג'ים וסימני פיסוק כדי לא לפגוע בסמנטיקה רגשית. לאחר מכן הופעל מודל PySentimiento לסיווג סנטימנט באנגלית, אשר החזיר לכל ציוץ תווית סנטימנט (POS/NEU/NEG) וכן הסתברויות לכל אחת מהקטגוריות.


כדי לשפר את איכות הסיווג ולהפחית מצב שבו טקסטים "גבוליים" מסווגים אוטומטית כנייטרליים, הוגדרה גם גישת **Dominance Rule**: כאשר התווית המקורית הייתה NEU אך אחת הקטגוריות האחרות (POS/NEG) קיבלה הסתברות גבוהה מספיק ($top_prob \geq 0.40$), התווית עודכנה לקטגוריה הדומיננטית. כך התקבלה תווית משופרת (sentiment_label_fixed) לצד התווית המקורית (sentiment_label_original), מה שמאפשר שקיפות ובקרה על השינוי.

בסיום התהליך נשמר קובץ תוצרים הכולל לכל ציוץ את תווית הסנטימנט המקורית והמשופרת, הסתברויות הסנטימנט, והטקסט לאחר ניקוי. בנוסף הופקו ויזואליזציות להשוואה בין ההתפלגות לפני/אחרי ולניתוח מגמות סנטימנט חודשיות לאורך זמן.

דוגמאות מהטבלה :

Tweet_id ▾	Username ▾	Created_at ▾	Text ▾	Text_en ▾	Sentiment_label ▾	Sentiment_positive ▾	Sentiment_negative ▴	Sentiment_neutral ▾
1887505891529	aa51_ansari	2025-02-06 14:1	Celebrating 300 @StBartholomev , by printing on a @CarlaSalvatore 's photos & com greatstbarts.com ...	Celebrating 300 @StBartholomev , by printing on a @CarlaSalvatore 's photos & com greatstbarts.com ...	POS	0.96	0	0.04
1319957543821	9tantiop	2020-10-24 11:0	You can listen to #existfestival #rc rootradio.live	You can listen to #existfestival #rc rootradio.live	POS	0.98	0	0.02
1741041296377	ahmadrezakzmi		کم رفت برای بخش وشنیه در فیلمو#وارم خوشتون بیاد	Well, our program #Oscar from the I hope you like it	POS	0.96	0	0.04
1984705097792	alimokhtari102		این و هم قدم شیم ن وجه رایج مملکت به امید دیدارتون	From this platform Cost: 450,000 to Hope to meet you	POS	0.97	0	0.03
1999742282401	2_rebelgirl		به نفع من « دادید بسمس مون برسیم بهلوی شیاد#	Thank you for giving Let's go to our Country #Pahlavi_Shayad	POS	0.98	0	0.02

Sentiment Distribution of Iranian Twitter Posts (Stage 21 Analysis)




התפלגות כללית של הרגשות:

מהגרף הראשון ניתן לראות כי כ-47 אחוז מהציצים סווגו כנייטרליים, כ-33 אחוז כשליליים וכ-20 אחוז כחיוביים. המשמעות היא שהשיח הכללי בקרב האוכלוסייה הנמדדת איננו חד משמעי רגשית, אך קיימת נטייה בולטת יותר לשליליות מאשר לחיוביות.

החלק הנייטרלי הגבוה יחסית משקף דיווחים, שיתופים ודיונים ענייניים שאינם טעונים רגשית באופן ברור. עם זאת, שיעור השליליות הגבוה יחסית מעיד על נוכחות משמעותית של ביקורת, תסכול או מתח בשיח הציבורי, במיוחד בהקשרים פוליטיים, כלכליים וחברתיים.


גרף כמותי במספרי ציצים:



בגרף העמודות ניתן לראות את הכמות המוחלטת של ציצים בכל קטגוריה. מעל עשרת אלפים ציצים סווגו כנייטרליים, כמעט שבעת אלפים כשליליים וכארבעת אלפים כחיוביים. חלוקה זו מחזקת את המסקנה כי אף שהשיח ברובו איננו קיצוני, קיימת שכבה משמעותית של רגשות שליליים בתוך האוכלוסייה הנבדקת.

ניתוח זה מאפשר לראות לא רק אחוזים אלא גם היקף ממשי של ביטוי רגשי, ומדגיש כי מספר הציצים השליליים איננו שולי אלא מהווה חלק מרכזי מהשיח.

מגמות לאורך זמן:



הגרף החודשי מציג את ממוצע ההסתברויות של כל רגש לאורך זמן. ניתן לראות תנודתיות גבוהה יחסית ברגש השלילי, עם תקופות שבהן עולה רמת השליליות באופן משמעותי. עליות אלו עשויות להתכתב עם אירועים פוליטיים, כלכליים או אזוריים המשפיעים על השיח הציבורי.

הרגש החיובי מופיע בעוצמה נמוכה יותר, אך גם הוא מציג תנודות תקופתיות. הרגש הנייטרלי שומר בדרך כלל על רמה יציבה יותר, ומשקף את הרוב היחסי של השיח שאינו מביע עמדה רגשית חדה.

המשמעות הכללית היא שהשיח בקרב האוכלוסייה האיראנית הנמדדת איננו אחיד לאורך זמן, אלא מושפע מאירועים ומהקשרים משתנים. קיימות תקופות של הגברת שליליות לצד תקופות מאוזנות יותר.

סיכום תובנות מרכזיות

הניתוח מצביע על כך שהשיח בטוויטר בקרב האוכלוסייה שנמדדה מאופיין באיזון יחסי בין ניטרליות לשליליות, כאשר השליליות בולטת יותר מהחיוביות. הדבר עשוי להעיד על מתחים, ביקורת או תחושת אי שביעות רצון בנושאים מסוימים, לצד נוכחות של דיון ענייני שאיננו רגשי.

שילוב הניתוח הכמותי עם ניתוח המגמות לאורך זמן מאפשר להבין לא רק מהו הרגש הדומיננטי, אלא גם כיצד הוא משתנה לאורך תקופות שונות. שלב זה מהווה בסיס להבנת האקלים הרגשי של השיח, ומהווה תשתית לשלבים הבאים בפרויקט, שבהם נבחנים גם רגשות מפורטים יותר ונושאים מרכזיים בשיח.

שלב 22 – ניתוח רגשות מפורט

שלב 22 עסק בניתוח רגשות מפורט (Emotion Analysis) של ציוצים של משתמשים מהאוכלוסייה שנדגמה, במטרה להבין את מצב הרוח בשיח ואת השינויים בו לאורך זמן. בשלב הראשון בוצע ניקוי טקסט כדי להשאיר תוכן מילולי נטו: הסרת קישורים, אזכורים של משתמשים, סימון "RT" והמרת האשטגים למילים רגילות. לאחר מכן הורץ מודל לזיהוי רגשות שמחזיר לכל ציוץ הסתברויות עבור שישה רגשות מרכזיים: שמחה, כעס, עצב, פחד, הפתעה וגועל. כדי להימנע ממצב שבו ציוצים רבים מסווגים לקטגוריה כללית ולא אינפורמטיבית, הוחלט לבחור לכל ציוץ את הרגש הדומיננטי לפי ההסתברות הגבוהה ביותר (כלומר כל ציוץ "נכפה" לכיוון רגש מסוים). כך התקבלה חלוקה מלאה של כל הציוצים לרגשות, מה שמאפשר להסיק מסקנות ברורות יותר על מצב השיח.

מתוצאות ההתפלגות הכללית עולה כי הרגשות הבולטים בשיח הם גועל ועצב (כל אחד בערך סביב חמישית מהציוצים), ולאחריהם כעס ושמחה (סביב 15–16 אחוז כל אחד). פחד מופיע גם הוא בשיעור משמעותי, בעוד שהפתעה היא הרגש הנדיר ביותר. באופן כללי, התמונה מצביעה על שיח טעון שמכיל הרבה תגובות שליליות ומתח רגשי, לצד שכבה לא קטנה של תכנים שנראים חיוביים יותר או אישיים.


בניתוח המגמות לאורך השנים והחודשים ניתן לראות שהרגשות אינם קבועים: יש תקופות שבהן עולה משקל של עצב/גועל או כעס, ולעומתן חודשים שבהם מופיעה עלייה יחסית בשמחה. לכן הערך המרכזי של השלב אינו רק "מי הרגש הכי גדול", אלא היכולת לזהות שינויים לאורך זמן ולחבר אותם להקשר של תקופות ואירועים.

Tweet_id	Username	Created_at	Text	Text_en	Sentiment_label	Clean_text	Emotion_label	Emotion_top_p	Emotion_joy	Emotion_anger
2023116922686	alyamaniyeen	2026-02-15 19:2	رئيس دونالد ترمب حسيني الخامنئي	All the kings and Donald Trump..	NEU	All the kings and	disgust	0.97	0	0.01
			لعالم دونالد ترمب أقاي خامنهئي	The most amazing Aqai Khamenei...						
2023113351409	alyamaniyeen	2026-02-15 19:1	لالتريكية القبلية لللكيان الصهيوني	Israel trains its soldiers Focusing on the	NEG	Israel trains its soldiers	disgust	0.94	0	0.05
2023110044905	alyamaniyeen	2026-02-15 18:5	جيك « في إسرائيل بر قلقاً في إسرائيل	"Jink" warning in Turkey's announcement	NEG	"Jink" warning in	fear	0.99	0	0
			الإعلام الإسرائيلي للسلطة التركية	Israeli media: "Our entire territory						
							Emotion_sadness	Emotion_fear	Emotion_surprise	Emotion_disgust
							0	0	0	0.97
							0	0	0	0.94
							0	0.99	0	0

גרף עמודות – התפלגות רגשות:

הגרף מציג כמה ציורים סווגו לכל אחד מששת הרגשות. ניתן לראות שרגשות של גועל ועצב מופיעים בשיעור גבוה יחסית, בעוד שהפתעה נדירה, מה שמרמז על שיח שמרבה בתגובות שליליות או ביקורתיות.


Emotion Distribution - Cleaned Text + Smart Neutral Handling
(Stage 22)



גרף עוגה – אחוזים מכל רגש:

הגרף מציג את החלוקה באחוזים ומאפשר להבין את התמונה הכללית בצורה מהירה. התפלגות האחוזים מחזקת את המסקנה שהשיח כולל שכבה משמעותית של רגשות שליליים לצד נוכחות בינונית של שמחה.


**Emotion Distribution - Cleaned Text + Smart Neutral Handling
(Stage 22)**




גרפים שנתיים (2022 – 2026)

גרפי המגמות לשנה מציגים כיצד ההסתברות הממוצעת לכל רגש משתנה לאורך חודשי השנה. כך ניתן לזהות חודשים "טעונים" שבהם רגשות כמו עצב/כעס/גועל מתחזקים, לעומת תקופות שבהן קיימת עלייה יחסית בשמחה.

בשנת 2022 ניתן לראות תנודתיות יחסית בין הרגשות. במחצית השנייה של השנה נרשמת עלייה ניכרת בעצב, ובמידה מסוימת גם בכעס. במקביל, רגש הגועל מציג קפיצות חדות באמצע השנה, דבר שמעיד על תקופות של תגובות רגשיות חריפות בשיח. השמחה מופיעה אך אינה דומיננטית לאורך השנה, והיא נעה סביב רמות בינוניות. התמונה הכוללת מצביעה על שיח מתוח יחסית, עם התחזקות של רגשות שליליים לקראת סוף השנה.




בשנת 2023 ניכרת עלייה משמעותית ברגש השמחה, במיוחד באמצע השנה ובסופה. במקביל, רגשות כמו עצב וכעס קיימים אך ברמות נמוכות יותר בהשוואה לשנה הקודמת. רגש הגועל מופיע במידה מתונה, ואילו פחד והפתעה נשארים נמוכים יחסית לאורך רוב חודשי השנה. ניתן לומר כי 2023 מציגה שיח מגוון יותר רגשית, עם איזון יחסי בין רגשות חיוביים לשליליים, ואף תקופות שבהן השיח נראה חיובי יותר.




בשנת 2024 התמונה יציבה יחסית. רגש השמחה נשאר נוכח לאורך רוב השנה ברמה בינונית, בעוד שעצב וכעס נשארים ברמות מתונות וללא קפיצות חדות במיוחד. עם זאת, ניתן לראות עלייה בגועל באמצע השנה, דבר שעשוי להעיד על אירועים נקודתיים שעוררו תגובות רגשיות חזקות. באופן כללי, השיח בשנה זו פחות תנודתי ויותר מאוזן בהשוואה ל-2022.

Emotion Trends - Year 2024
(Stage 22 - Cleaned Text + Smart Neutral Handling)




בשנת 2025 ניכרת ירידה יחסית בתנודתיות. רגשות הכעס והעצב מופיעים ברמות נמוכות- בינוניות לאורך השנה, ללא זינוקים משמעותיים. השמחה יציבה יחסית אך אינה דומיננטית בצורה קיצונית. רגש הגועל ממשיך להופיע בשיעור מורגש, אך בצורה מתונה יותר לעומת שנים קודמות. התמונה הכוללת מצביעה על שיח רגשי קבוע יותר ופחות קיצוני.

Emotion Trends - Year 2025
(Stage 22 - Cleaned Text + Smart Neutral Handling)



בשנת 2026, למרות שמדובר בשני חודשי נתונים בלבד (ינואר-פברואר), ניתן לזהות דפוס רגשי ברור ומשמעותי. בתקופה זו התרחשו באיראן הפגנות נגד המשטר ואירועי אלימות ומוות, והדבר בא לידי ביטוי מובהק בנתונים. רגש הגועל מופיע ברמה גבוהה יחסית כבר בתחילת השנה, וניכר כי הוא בולט יותר ביחס לרגשות אחרים. במקביל, גם כעס ועצב נוכחים, אך הגועל הוא הרגש הדומיננטי ביותר בתקופה זו. ממצא זה מחזק את הקשר בין אירועים פוליטיים וחברתיים חריפים לבין שינוי מובהק בפרופיל הרגשי של השיח הציבורי ברשתות החברתיות.

Emotion Trends - Year 2026
(Stage 22 - Cleaned Text + Smart Neutral Handling)



שלב 23 – זיהוי נושאים באמצעות BERTopic

בשלב זה יושמה שיטת זיהוי נושאים מתקדמת במטרה לאתר את מוקדי השיח המרכזיים בטוויטר בקרב האוכלוסייה האיראנית. לצורך כך נעשה שימוש באלגוריתם BERTopic המשלב הטמעות סמנטיות של משפטים יחד עם אלגוריתמי צמצום ממדים ואשכולות, ומאפשר גילוי נושאים בצורה בלתי מונחית.

טעינת הנתונים וניקוי מינימלי

תחילה נטענו כלל הציוצים מהקובץ המעודכן הכולל גם תוצאות ניתוח רגשות. לצורך מידול נושאים בוצע ניקוי טקסט מינימלי בלבד: הסרת קישורים, אזכורים, סימון שיתוף והמרת האשטגים למילים רגילות. נשמרו אימוג'ים וסימני פיסוק כדי לא לפגוע בהקשר הסמנטי.

לאחר הסרת טקסטים ריקים התקבל מאגר מלא של ציוצים באנגלית מתורגמת, עם טווח שנים רחב.

חיפוש היפר-פרמטרים

בהתאם להנחיות הקורס בוצע Grid Search על תת-מדגם של 7.5% מהנתונים, במטרה לבחור את הפרמטרים האופטימליים.

נבדקו:

- ערכי min_topic_size שונים
- ערכי n_neighbors שונים

לכל שילוב חושבו:

- מספר נושאים
- יחס חריגים
- מדד קוהרנטיות (c_v)

הבחירה בוצעה לפי הקריטריונים:

1. בין 10 ל-60 נושאים
2. יחס חריגים נמוך מ-20%
3. הקוהרנטיות הגבוהה ביותר מבין המועמדים

כך התקבלה קונפיגורציה מאוזנת שמצד אחד לא יוצרת ריבוי אשכולות מיותר, ומצד שני שומרת על איכות סמנטית גבוהה.

התאמת המודל על כלל הדאטה

לאחר בחירת הפרמטרים האופטימליים, הותאם המודל על כלל הציוצים.

השלבים כללו:

- יצירת הטמעות טקסטואליות באמצעות מודל שפה מתקדם
- צמצום ממדים
- אשכול באמצעות HDBSCAN
- שיוך כל ציוץ לנושא ולציון הסתברות

לאחר ההתאמה בוצעה הפחתת נושאים למספר יעד של 40 נושאים לצורך פרשנות טובה יותר וקריאות בדוח.

בנוסף, בוצעה הפחתת חריגים במידת הצורך כדי להקטין את מספר הציוצים שלא שובצו לנושא ברור.

תוצרי השלב

1) קובץ Data/Topics.csv הכולל:

- מזהה ציוץ
- תאריך
- טקסט מתורגם
- מזהה נושא
- הסתברות שיוך


Tweet_id ▼	Created_at ▼	Text_translated	Topic_id ▼	Probability ▼
2023116922686	2026-02-15 19:2	All the kings and Donald Trump.. The most amazin Aqai Khamenei...	34	0.05
2023113351409	2026-02-15 19:1	Israel trains its s Focusing on the	9	0.1
2023110044905	2026-02-15 18:5	"Jink" warning in Turkey's announ Israeli media: "Our entire terri	0	0.13
2023109089757	2026-02-15 18:5	Watch these 15 : They are not eve Amir Etemadi (fo This bastard war	4	0.61
2023105824927	2026-02-15 18:4	One of the CIA k #Suleiman_Al-Fa	1	0.17

2) טבלת מידע מלאה על הנושאים:

- מספר ציוצים בכל נושא
- מילות מפתח מרכזיות
- ציוצים מייצגים

4	731	4_pahlavi_reza_shah_the	['pahlavi', 'reza', 'shah', 'the', 'c
5	667	5_team_football_the_in	['team', 'football', 'the', 'in', 'g
6	838	6_al_truth_told_the	['al', 'truth', 'told', 'the', 'iraq', ']
7	748	7_com_song_music_album	['com', 'song', 'music', 'album'
8	1897	8_you_my_life_and	['you', 'my', 'life', 'and', 'that', ']
9	531	9_gaza_israel_the_of	['gaza', 'israel', 'the', 'of', 'israe
10	932	10_old_was_killed_his	['old', 'was', 'killed', 'his', 'year
11	665	11_night_good_morning_it	['night', 'good', 'morning', 'it',
12	242	12_iranmassacre_kingrezapahlavi_iranrevolution2	['iranmassacre', 'kingrezapahl
13	269	13_alarabiya_breaking_ukraine_russia_zelensky	['alarabiya_breaking', 'ukraine'
14	444	14_don_you_eat_it	['don', 'you', 'eat', 'it', 'bread', ']

מגמות נושאים לאורך זמן:



הגרף מציג את חמשת הנושאים המרכזיים שזוהו על ידי מודל זיהוי הנושאים, ואת חלקם היחסי מתוך כלל השיח בכל חודש בין השנים 2022 ל-2026. כל צבע מייצג נושא אחר, והשטח של כל צבע משקף את אחוז הציורים החודשיים ששויכו לאותו נושא.

ניתן לראות כי חלק מהנושאים שומרים על נוכחות יציבה לאורך זמן, בעוד אחרים מופיעים בעוצמה גבוהה בתקופות מסוימות בלבד. הדבר מעיד על כך שהשיח הציבורי באיראן מושפע מאירועים נקודתיים, פוליטיים וחברתיים, אשר גורמים לעלייה זמנית בעיסוק בנושא מסוים.

לדוגמה, יש חודשים בהם נושא מסוים תופס נתח גדול במיוחד מהשיח, ולאחר מכן דועך. תבנית זו משקפת תגובתיות של הציבור לאירועים אקטואליים, מחאות, אירועים ביטחוניים או סוגיות דתיות וחברתיות.

באופן כללי ניתן לראות כי השיח אינו סטטי, אלא משתנה באופן דינמי בהתאם להקשר הזמן והאירועים במדינה.

נושא 0 – יחסי איראן והמערב ופוליטיקה כללית – הוא הנושא המרכזי והדומיננטי ביותר לאורך התקופה. לצדו בולטים נושאים דתיים (נושא 1), שיח אישי וחברתי (נושא 8), פעילות אופוזיציה מחוץ לאיראן (נושא 2), ונושא הקשור למוות ואירועים אלימים (נושא 10).

הגרף מציג את חמשת הנושאים המרכזיים בשיח האיראני בטוויטר בין השנים 2022–2026, כאשר כל חודש מוצג לפי החלק היחסי של כל נושא מתוך כלל הציורים באותו חודש. כלומר, הגרף אינו מציג מספר ציורים מוחלט אלא את אחוז השיח שכל נושא תפס באותו זמן. כך ניתן לראות כיצד מוקד הדיון הציבורי משתנה לאורך השנים.

הנושא הדומיננטי ביותר הוא נושא 0 – יחסי איראן והמערב ופוליטיקה כללית. לאורך רוב התקופה הוא תופס נתח משמעותי מהשיח, במיוחד בתקופות של מתיחות מדינית או אירועים פוליטיים מרכזיים. נושא 1 – שיח דתי ונאומים של עבדולחמיד – מופיע בגלים, בעיקר בתקופות של מחאה או ביקורת ציבורית שבהן לשיח הדתי יש משקל ציבורי. נושא 8 – חיים אישיים ושיח יומיומי – מייצג את הממד החברתי והאישי של המשתמשים, ולעיתים מתחזק כאשר השיח

הפוליטי נחלש. נושא 2 – ועידת מינכן והפזורה האיראנית – בולט בעיקר סביב אירועים בינלאומיים הקשורים לאופוזיציה מחוץ לאיראן. נושא 10 – הרג ואירועים אלימים – מתחזק בתקופות של מחאות, עימותים ודיווחים על מקרי מוות.

כאשר מחברים ממצאים אלו לניתוח הרגש והרגשות בשלבים הקודמים, מתקבלת תמונה עקבית: בתקופות שבהן נושא 10 והנושאים הפוליטיים מתחזקים, נרשמת גם עלייה ברגשות שליליים כמו כעס, עצב וגועל. לעומת זאת, כאשר השיח האישי או הדתי מתגבר, ניתן לראות שינוי באיזון הרגשי ולעיתים עלייה ברגש של שמחה או תקווה. כך, ניתוח הנושאים והרגשות יחד מאפשר להבין לא רק על מה הציבור מדבר, אלא גם באיזה מצב רגשי הוא נמצא ביחס לאירועים המתרחשים במדינה.

הגרף למעשה ממחיש את הדינמיקה של השיח הציבורי באיראן – מעבר מתמיד בין פוליטיקה, מחאה, דת וחיים אישיים – ואת הקשר הישיר בין אירועים במציאות לבין תוכן ורגש ברשת החברתית.

המשמעות המחקרית

שלב זה מאפשר לזהות את מוקדי השיח המרכזיים בציבור האיראני לאורך השנים. השילוב בין ניתוח נושאים לניתוח רגשות שבוצע בשלב הקודם מאפשר להבין לא רק מה מדברים – אלא גם כיצד מרגישים ביחס לנושאים אלו.

כך ניתן לבחון:

- אילו נושאים מתחזקים בתקופות מחאה או משבר
- האם נושאים פוליטיים מלווים בעלייה בכעס או גועל
- כיצד משתנה מבנה השיח לאורך זמן

השלב מספק תשתית אנליטית להבנת דינמיקת השיח הציבורי באיראן בצורה מבוססת נתונים.

סיכום :

ניתוח הנתונים משקף שיח ציבורי שמתקיים בתוך מציאות פוליטית מורכבת. בשנים האחרונות איראן חוותה גלי מחאה משמעותיים נגד המשטר הדתי בהנהגת האייתולות, בין היתר על רקע משבר כלכלי, מגבלות חברתיות, פגיעה בזכויות אזרחיות ואירועי דיכוי אלימים. מגמות אלו באות לידי ביטוי ברור בניתוח הרגשי: בתקופות של מחאות, עימותים ודיווחים על הרוגים נרשמת עלייה חדה ברגשות של גועל, כעס ועצב. השיח משקף תסכול עמוק וחוסר אמון כלפי הממסד, ולעיתים גם קריאות לשינוי פוליטי.

בנוסף, המתיחות האזורית והבינלאומית – לרבות היחסים המתוחים עם ארצות הברית והעימות העקיף עם ישראל – משתלבת בשיח הפוליטי ומעצימה רגשות של פחד, כעס ולעיתים גם לאומיות ותחושת איום חיצוני. אירועים ביטחוניים או הצהרות מדיניות בולטות גורמים לעלייה בנושאים הקשורים למדיניות חוץ ולביטחון, ובמקביל מתבטאים גם בשינוי בפרופיל הרגשי של השיח.

עם זאת, לצד השיח הפוליטי והביקורתי, הנתונים מראים כי הציבור האיראני אינו עוסק אך ורק במחאה ובמשטר. קיימים גם ביטויי חיים אישיים, תרבות, ספורט ודת, ולעיתים אף תקווה ושמחה. מורכבות זו מצביעה על חברה שחיה תחת מערכת פוליטית ריכוזית ונוקשה, אך ממשיכה לנהל שיח ציבורי מגוון, רגיש ודינמי.

בסיכום כולל, הפרויקט מדגים כיצד ניתוח נתונים מרשתות חברתיות מאפשר לזהות את הקשר הישיר בין אירועים פוליטיים וביטחוניים לבין מצב הרוח הציבורי. השיח הדיגיטלי משמש מדד בלתי פורמלי אך משמעותי להבנת הלכי הרוח בחברה האיראנית, במיוחד בתקופות של מתיחות, מחאה ושינויים פוליטיים.

